

INSTITUTO FEDERAL DE SERGIPE
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Rone Clay Oliveira Andrade

Dificuldades no Ensino de Estruturas de Dados com Ênfase em Árvores Binárias de Busca: Uma Análise Comparativa entre o Método Tradicional e o Uso de um Software Educativo

Itabaiana/SE
2026

Rone Clay Oliveira Andrade

Dificuldades no Ensino de Estruturas de Dados com Ênfase em Árvores Binárias de Busca: Uma Análise Comparativa entre o Método Tradicional e o Uso de um Software Educativo

Monografia apresentada à Coordenação de Ciência da Computação do Campus Itabaiana, do Instituto Federal de Sergipe (IFS), como pré-requisito para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Me. Marlos Tacio Silva
Coorientador: Prof. Me. Levi da Costa Mota

Itabaiana/SE
2026

Andrade, Rone Clay Oliveira.
A554 Dificuldades no ensino de estruturas de dados com ênfase em árvores binárias de busca: uma análise [...]. / Rone Clay Oliveira Andrade. – Itabaiana, 2026.
69f.: il.

Trabalho de conclusão de curso (Bacharelado em Ciência da Computação) – Instituto Federal de Educação, Ciência e Tecnologia de Sergipe – IFS, 2026.

Orientador: Prof. Marlos Tacio Silva. Coorientador: Levi da C. Mota.

1. Estrutura de dados. 2. Árvore binária de busca 3. Objeto de aprendizagem. 4. Visualização algorítmica. 5. Visualgo. I. IFS. II. Andrade, Rone Clay Oliveira. III. Silva, Marlos Tacio. IV. Mota, Levi da Costa. V. Título.

CDU: 004.43:37.014.53

Ficha catalográfica elaborada pela bibliotecária Jeane Gomes dos Santos CRB 5/1293

Rone Clay Oliveira Andrade

Dificuldades no Ensino de Estruturas de Dados com Ênfase em Árvores Binárias de Busca: Uma Análise Comparativa entre o Método Tradicional e o Uso de um Software Educativo

Monografia apresentada à Coordenação de Ciência da Computação do Campus Itabaiana, do Instituto Federal de Sergipe (IFS), como pré-requisito para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Me. Marlos Tacio Silva
Coorientador: Prof. Me. Levi da Costa Mota

Trabalho defendido e aprovado em: 04/02/2026

BANCA EXAMINADORA

Documento assinado digitalmente
gov.br MARLOS TACIO SILVA
Data: 11/02/2026 23:39:10-0300
Verifique em https://validar.iti.gov.br

Prof° Me. Marlos Tacio Silva (Orientador)
Instituto Federal de Sergipe

Documento assinado digitalmente
gov.br LEVI DA COSTA MOTA
Data: 12/02/2026 15:44:39-0300
Verifique em https://validar.iti.gov.br

Prof° Me. Levi da Costa Mota (Coorientador)
Instituto Federal de Sergipe

Documento assinado digitalmente
gov.br GLEISER RODRIGUES DE MELO
Data: 12/02/2026 15:52:31-0300
Verifique em https://validar.iti.gov.br

Profº Me. Gleiser Rodrigues de Melo (Membro examinador)
Instituto Federal de Sergipe

Documento assinado digitalmente
gov.br CARLOS AUGUSTO DE SANTANA ALMEIDA
Data: 13/02/2026 13:38:09-0300
Verifique em https://validar.iti.gov.br

Prof° Me. Carlos Augusto de Santana Almeida (Membro examinador)
Instituto Federal de Sergipe

AGRADECIMENTOS

Gostaria de agradecer primeiramente a minha namorada, Yris, que sabe sobre cada correção e ajuste que foi preciso ser feito no trabalho, e me apoiou e me incentivou a todo momento para conclusão, estando comigo em momentos que o cansaço batia e em momentos de felicidade ao encerrar mais um período de correção.

Gostaria de agradecer também a minha família que sempre me incentivou em relação a importância dos estudos, e reconhecimento ao meu esforço.

Outra parte da minha vida que não poderia deixar de agradecer são meus amigos, que estiveram comigo em cada momento e entenderam os momentos que eu precisava focar nesse trabalho e em outras atividades do curso.

Fica o agradecimento aos meus professores, desde o fundamental até o superior, que estiveram comigo na minha jornada acadêmica. Em especial ao meu orientador e coorientador, que deram ideias, me ouviram e aconselharam.

RESUMO

O ensino de Estruturas de Dados, especificamente Árvores Binárias de Busca, caracteriza-se por um elevado nível de abstração, impondo desafios à formação de modelos mentais pelos discentes. Este trabalho investigou o impacto da ferramenta de visualização *VisuAlgo* como recurso pedagógico na disciplina de Estruturas de Dados II do Instituto Federal de Sergipe, Campus Itabaiana. Adotou-se uma abordagem quantitativa quase-experimental com pré e pós-teste, envolvendo uma amostra de 11 estudantes divididos em Grupo Controle (aula expositiva tradicional) e Grupo Experimental (uso da ferramenta). A análise dos dados foi triangulada com métricas de usabilidade (*System Usability Scale* - SUS) e satisfação (*Net Promoter Score* - NPS). Os resultados revelaram uma dicotomia de desempenho baseada na complexidade cognitiva: o Grupo Experimental obteve superioridade nos fundamentos estruturais (95,8% de acerto), validando a Teoria da Codificação Dual para a visualização estática. Em contrapartida, o Grupo Controle apresentou desempenho significativamente superior na lógica de percursos recursivos (86,7% contra 44,4%), indicando que a visualização passiva das animações não foi suficiente para ensinar a pilha de execução (*stack trace*) sem a mediação docente detalhada. A avaliação de usabilidade classificou a ferramenta como "Boa" (SUS 73,75) e indicou alta lealdade (NPS +50), embora tenha sido identificada uma correlação direta entre dificuldades de interface e baixo desempenho acadêmico (Carga Cognitiva Estranha). Conclui-se que o *VisuAlgo* não substitui a instrução formal em tópicos de alta abstração lógica, devendo ser utilizado como recurso complementar para a fase de apresentação conceitual.

Palavras-chave: Estruturas de Dados. Árvores Binárias de Busca. Objetos de Aprendizagem. Visualização Algorítmica. *VisuAlgo*. Ensino de Computação.

ABSTRACT

The teaching of Data Structures, specifically Binary Search Trees, is characterized by a high level of abstraction, posing challenges to the formation of mental models by students. This study investigated the impact of the VisuAlgo visualization tool as a pedagogical resource in the Data Structures II course at the Federal Institute of Sergipe, Itabaiana Campus. A quasi-experimental quantitative approach with pre- and post-tests was adopted, involving a sample of 11 students divided into a Control Group (traditional lecture) and an Experimental Group (tool usage). Data analysis was triangulated with usability metrics (System Usability Scale - SUS) and satisfaction metrics (Net Promoter Score - NPS). The results revealed a performance dichotomy based on cognitive complexity: the Experimental Group showed superiority in structural fundamentals (95.8% accuracy), validating the Dual Coding Theory for static visualization. Conversely, the Control Group presented significantly superior performance in recursive traversal logic (86.7% vs. 44.4%), indicating that passive visualization of animations was insufficient to teach the execution stack trace without detailed teacher mediation. The usability assessment classified the tool as "Good" (SUS 73.75) and indicated high loyalty (NPS +50), although a direct correlation was identified between interface difficulties and low academic performance (Extraneous Cognitive Load). It is concluded that VisuAlgo does not replace formal instruction in topics of high logical abstraction and should be used as a complementary resource for the conceptual presentation phase.

Keywords: Data Structures. Binary Search Trees. Learning Objects. Algorithm Visualization. VisuAlgo. Computer Science Education.

LISTA DE TABELAS

Tabela 1 - Características dos estudos incluídos pela revisão 22
Tabela 2 - Estatísticas Descritivas das Notas Totais 40
Tabela 3 - Perfil Individual dos Estudantes (Grupo Experimental) 48

LISTA DE FIGURAS

Figura 1 - Estruturas de Dados 14
Figura 2 - Representação de uma Árvore Binária de Busca..... 15
Figura 3 - Representação de uma lista Não Ordenada 15
Figura 4 - Fluxograma de seleção de artigos 22
Figura 5 - Fluxograma das etapas da pesquisa experimental 34
Figura 6 - Distribuição das médias de ganho de aprendizagem..... 41
Figura 7 - Gráfico do Impacto do tratamento por habilidade específica..... 42
Figura 8 - Gráfico da Avaliação de Usabilidade (*System Usability Scale*) 43
Figura 9 - Gráfico da Classificação *Net Promoter Score* (NPS) 45
Figura 10 - Gráfico de agrupamento dos perfis de aprendizagem..... 48

SUMÁRIO

1. INTRODUÇÃO 10

1.1. CONTEXTUALIZAÇÃO 10
1.2. PROBLEMÁTICA 10
1.3. JUSTIFICATIVA 11
1.4. OBJETIVOS 11
1.4.1. Objetivo Geral 12
1.4.2. Objetivos Específicos 12
1.5. ORGANIZAÇÃO DO TRABALHO 12

2. FUNDAMENTAÇÃO TEÓRICA 13

2.1. ALGORITMOS E ESTRUTURAS DE DADOS 13
2.2. ÁRVORES BINÁRIAS DE BUSCA 14
2.3. DESAFIOS NO ENSINO E APRENDIZAGEM 16
2.4. TEORIAS DE APRENDIZAGEM NA COMPUTAÇÃO 16
2.5. TEORIA DA CODIFICAÇÃO DUAL 16
2.6. TEORIA DA CARGA COGNITIVA 17
2.7. A MEDIAÇÃO NO SOCIOINTERACIONISMO 18
2.8. A FERRAMENTA *VISUALGO* 18

3. TRABALHOS RELACIONADOS 19

3.1. PROTOCOLO DA REVISÃO SISTEMÁTICA 19
3.2. FERRAMENTAS E ESTRATÉGIAS IDENTIFICADAS 21
3.3. SÍNTESE E LACUNAS DE PESQUISA 30

4. METODOLOGIA 31

4.1. DELINEAMENTO DO ESTUDO 31
4.2. PARTICIPANTES E CONTEXTO 31
4.3. INSTRUMENTOS DE COLETA DE DADOS 31
4.4. QUESTIONÁRIO DE DESEMPENHO (PRÉ E PÓS-TESTE) 32
4.5. SYSTEM USABILITY SCALE (SUS) 32
4.6. NET PROMOTER SCORE (NPS) 33
4.7. PROCEDIMENTOS METODOLÓGICOS 33
4.8. ANÁLISE DOS DADOS 35
4.9. TRATAMENTO E ANÁLISE DESCRITIVA DOS DADOS 35
4.10. ANÁLISE DOS DADOS DE PERCEPÇÃO 35
4.11. AMEAÇAS À VALIDADE 36
4.12. ASPECTOS ÉTICOS 37
4.13. AMBIENTE EXPERIMENTAL E PROTOCOLO DE USO DO *VISUALGO* 38
4.14. CONTROLE DE VARIÁVEIS E MEDIAÇÃO PEDAGÓGICA 38
4.15. TRANSPARÊNCIA E CIÊNCIA ABERTA 39

5. RESULTADOS E DISCUSSÃO 40

5.1. PANORAMA GERAL E IMPACTO NA APRENDIZAGEM 40
5.2. ANÁLISE ESTRATIFICADA POR TÓPICO 41
5.3. USABILIDADE (SUS) E SATISFAÇÃO (NPS) 43
5.4. ANÁLISE DE USABILIDADE (SUS) 43
5.5. ÍNDICE DE LEALDADE (NPS) 44
5.6. DISCUSSÃO E COMPARAÇÃO COM A LITERATURA 45
5.7. A CONSTRUÇÃO DO MODELO MENTAL E A CODIFICAÇÃO DUAL 46
5.8. A "ILUSÃO DE COMPETÊNCIA" E A DEPENDÊNCIA DA FERRAMENTA 46
5.9. USABILIDADE COMO FATOR DE EXCLUSÃO 46
5.10. ANÁLISE INDIVIDUAL: TRIANGULAÇÃO ENTRE DESEMPENHO E PERCEPÇÃO 47

6. CONCLUSÃO 50
6.1. SÍNTESE DOS ACHADOS E DIÁLOGO COM A LITERATURA 50
6.2. VALIDAÇÃO DA USABILIDADE E CARGA COGNITIVA 51
6.3. IMPLICAÇÕES PARA A PRÁTICA DOCENTE 51
6.4. LIMITAÇÕES DO ESTUDO 51
6.5. TRABALHOS FUTUROS 52
7. REFERÊNCIAS 53
8. APÊNDICES 58
8.1. APROVAÇÃO DO COMITÊ DE ÉTICA DO INSTITUTO FEDERAL DE SERGIPE (IFS) 58
8.2. QUESTIONÁRIO DE DESEMPENHO 59
8.3. QUESTIONÁRIO DE SATISFAÇÃO DO USO DA FERRAMENTA 66

1. INTRODUÇÃO

1.1. Contextualização

Nos cursos de Ciência da Computação, as disciplinas de algoritmos e estruturas de dados são componentes basilares para a formação do discente. Essa disciplina abrange conteúdos importantes, como listas, pilhas, filas, árvores e grafos, e tem como objetivo a construção e a análise de tais estruturas. As diretrizes curriculares internacionais CS2023, da *Association for Computing Machinery* (ACM), validam essa importância. Nelas, tais conteúdos são classificados como fundamentais e mandatórios para estudantes da área, integrando o chamado "CS *Core*" (KUMAR et al., 2024).

A disciplina de estruturas de dados é fundamental para a formação do desenvolvedor de *software* e tem reconhecida importância. No entanto, ela apresenta dificuldades significativas para os alunos, o que se reflete em altos índices de reprovação. Em um estudo na Universidade Estadual de Montes Claros (Unimontes), a disciplina "Algoritmos e Estruturas de Dados I" foi identificada como uma das que apresentaram maior índice de reprovação entre 2014 e 2019, com 56,29% (PATTA; MACEDO, 2021). De forma similar, em um levantamento na Universidade Federal da Paraíba (UFPB), verificou-se que apenas 68,8% dos alunos obtiveram aprovação em Estruturas de Dados, sendo esta a quinta disciplina com menor taxa de aprovação (DUARTE, 2021).

Diversos fatores dificultam a aprendizagem, sendo um dos principais a metodologia de ensino tradicional, baseada em aulas expositivas e exercícios. Como consequência, os estudantes se desmotivam por não conseguirem visualizar a aplicação prática dos conceitos, dada a sua natureza abstrata e a dificuldade em associá-los com o mundo real (FREITAS et al., 2014). Essa dificuldade de assimilação é ainda mais evidente no caso da estrutura de dados de árvores, por seu maior nível de abstração e falta de um paralelo intuitivo com o cotidiano (SOUZA et al., 2022).

1.2. Problemática

Diversas abordagens foram propostas no âmbito de ferramentas

computacionais, desde jogos como o SORTIA (BATTISTELLA et al., 2012) e *softwares* como o PORTEC (FREITAS et al., 2014), até aplicativos móveis como o ASCAA (OLIVEIRA et al., 2016). Outras iniciativas exploraram tecnologias emergentes, como a Realidade Aumentada com o SEDRA (HARA; SISCOUTTO, 2018), ou extensões de ambientes de programação, como o DSAScratch (JAGADEESHA et al., 2023).

Apesar dessas iniciativas, persiste a necessidade de validar ferramentas de visualização que sejam acessíveis e integrem-se eficazmente ao currículo de graduação. Diante desse cenário de dificuldade de abstração e altos índices de reprovação, a presente pesquisa norteia-se pela seguinte questão:

O uso da ferramenta de visualização algorítmica *VisuAlgo*[1], como recurso complementar à aula expositiva, impacta positivamente o desempenho acadêmico e a satisfação dos discentes no aprendizado de Árvores Binárias de Busca?

1.3. Justificativa

O escopo deste trabalho foca na estrutura de dados de árvore binária de busca. Essa escolha se baseia em dois motivos principais: a pesquisa coincide com o período em que é ofertada a disciplina de Estruturas de Dados II, cujo conteúdo programático aborda o tópico de árvores; e a estrutura de árvores representa um salto de complexidade em relação às estruturas lineares (filas e pilhas), exigindo maior capacidade de abstração do aluno para compreender o balanceamento e a hierarquia dos nós.

A escolha da ferramenta *VisuAlgo* justifica-se por ser uma plataforma *web* gratuita, amplamente acessível e desenhada especificamente para auxiliar na visualização do comportamento dinâmico de algoritmos, permitindo que o aluno observe o passo a passo lógico das operações, preenchendo a lacuna deixada pelos desenhos estáticos do quadro negro. Investigar sua eficácia no contexto local do Instituto Federal de Sergipe contribui para a melhoria das práticas pedagógicas na instituição.

1.4. Objetivos

[1]https://visualgo.net/en/

1.4.1. Objetivo Geral

Analisar a influência do uso da ferramenta de visualização *VisuAlgo* no processo de ensino-aprendizagem de Árvores Binárias de Busca em uma turma de graduação.

1.4.2. Objetivos Específicos

- Realizar um levantamento bibliográfico sobre o ensino de estruturas de dados e o uso de ferramentas de visualização;
- Aplicar um experimento controlado com turmas de graduação, dividindo-os em grupo controle e grupo experimental;
- Comparar o desempenho discente entre o método tradicional (aula expositiva) e o uso da ferramenta *VisuAlgo*;
- Avaliar a usabilidade e a satisfação dos alunos quanto ao uso do *software* através de questionários padronizados (SUS e NPS).

1.5. Organização do Trabalho

Este trabalho está organizado em cinco capítulos. O Capítulo 2 (Fundamentação Teórica) apresenta os conceitos de Algoritmos, Estruturas de dados e Árvores Binárias de Busca. O Capítulo 3 (Trabalhos relacionados) revisa trabalhos relacionados ao uso de ferramentas visuais no ensino. O Capítulo 4 (Metodologia) detalha o delineamento experimental, a caracterização da amostra e os instrumentos de coleta de dados. O Capítulo 5 (Resultados e Discussão) exibe a análise estatística dos dados coletados, comparando o desempenho dos grupos e discutindo a avaliação de usabilidade. Por fim, o Capítulo 6 (Conclusão) retoma os objetivos alcançados, apresenta as conclusões do estudo e sugere trabalhos futuros.

2. FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta a base conceitual necessária para a compreensão da pesquisa. Inicialmente, são definidos os conceitos de algoritmos e estruturas de dados, destacando sua interdependência no desenvolvimento de *software*. Em seguida, o foco recai sobre as Árvores Binárias de Busca (BST), detalhando suas características, propriedades e operações fundamentais. Por fim, discute-se a importância da visualização no ensino de computação e são apresentados trabalhos relacionados que exploram ferramentas tecnológicas para o ensino de estruturas de dados, situando o *VisuAlgo* no contexto acadêmico atual.

2.1. Algoritmos e Estruturas de Dados

Um algoritmo é a formalização de um método para solucionar um problema. Segundo a definição clássica de Donald Knuth, um dos pioneiros da área, um algoritmo deve possuir cinco características essenciais (KNUTH, 1997): finitude (terminar após um número finito de passos), definitude (cada passo deve ser definido de forma precisa e sem ambiguidades), entrada (possuir zero ou mais valores de entrada), saída (produzir um ou mais valores de saída) e eficácia (todas as operações devem ser básicas o suficiente para serem realizadas em tempo finito). Essa estrutura lógica é o pilar da Ciência da Computação, permitindo modelar e resolver problemas de maneira sistemática e eficiente.

Enquanto os algoritmos definem os passos, as Estruturas de Dados determinam como as informações são organizadas, armazenadas e manipuladas para que esses passos sejam executados com eficiência. A relação indissociável entre esses dois conceitos foi imortalizada por Niklaus Wirth em sua famosa equação: Algoritmos + Estruturas de Dados = Programas (WIRTH, 1976). A escolha da estrutura de dados adequada é, portanto, uma decisão crítica que impacta diretamente o desempenho, a complexidade e a elegância de uma solução computacional.

As estruturas de dados podem ser classificadas como lineares (vetores, listas, pilhas e filas), que organizam os dados em sequência, e não lineares (árvores e grafos), que representam relações hierárquicas ou de rede (CORMEN et al., 2012). Estruturas como pilhas e filas possuem analogias diretas com o mundo real (uma pilha

de pratos, uma fila de banco), o que facilita o entendimento intuitivo. Em contrapartida, estruturas não lineares como as árvores exigem um nível de abstração consideravelmente maior (ROJAS-SALAZAR; RAMÍREZ-ALFARO; HAÁHR, 2020).

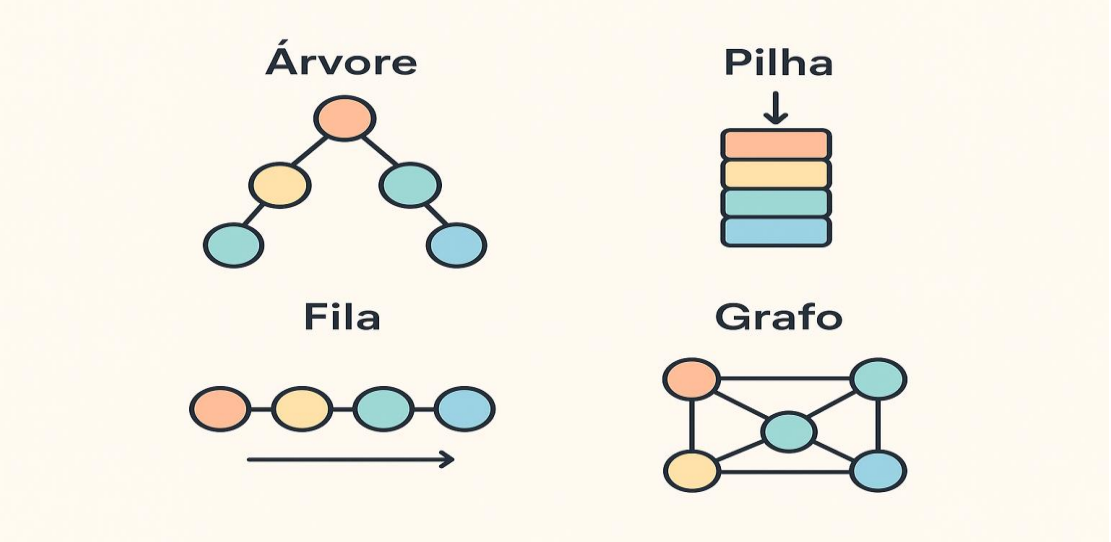


Figura 1 - Estruturas de Dados

Fonte: Elaborado pelo autor (2026)

2.2. Árvores Binárias de Busca

Dentre as estruturas não lineares, a árvore binária de busca (Binary Search Tree - BST) se destaca por sua eficiência em operações de busca, inserção e remoção de dados. Trata-se de uma estrutura hierárquica na qual cada nó possui no máximo dois filhos, comumente chamados de subárvore esquerda e subárvore direita. O que define uma BST é a sua propriedade fundamental: para qualquer nó x, todos os valores na sua subárvore esquerda devem ser menores ou iguais ao valor de x, enquanto todos os valores na sua subárvore direita devem ser maiores ou iguais. Essa propriedade invariante permite que operações sejam realizadas com uma complexidade de tempo média de O (log n), onde n é o número de nós.

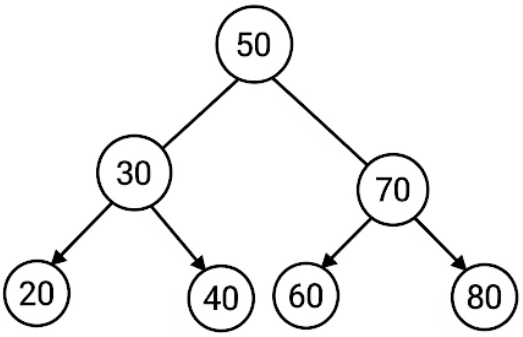


Figura 2 - Representação de uma Árvore Binária de Busca

Fonte: Elaborado pelo autor (2026)

Para colocar essa eficiência em perspectiva, considere uma estrutura de dados linear, como uma lista. Nela, para encontrar um elemento, seria necessário percorrer, no pior caso, todos os n elementos, resultando em uma complexidade de tempo de O(n). Em um cenário com 1 milhão de itens, a busca em uma árvore binária de busca balanceada exigiria cerca de 20 comparações (log2 1.000.000≈20), ao passo que a busca na lista poderia exigir até 1 milhão de comparações. Esse ganho de performance torna a BST uma escolha muito superior para aplicações que demandam agilidade em grandes volumes de informação.

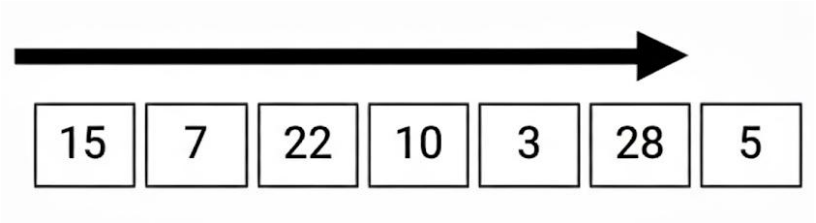


Figura 3 - Representação de uma lista Não Ordenada

Fonte: Elaborado pelo autor (2026)

Esse tipo de eficiência não é apenas teórico: árvores de busca balanceadas, como AVL, *Red-Black Trees* e *B-Trees*, são amplamente empregadas em sistemas reais devido à sua capacidade de manter operações de busca, inserção e remoção em tempo logarítmico. Bancos de dados utilizam *B-Trees* para indexação, sistemas de arquivos modernos organizam diretórios com variantes de árvores balanceadas e diversas linguagens de programação implementam coleções ordenadas com essas estruturas, garantindo alto desempenho mesmo em grandes volumes de dados (GOODRICH; TAMASSIA; GOLDWASSER, 2014).

A eficiência da BST, contudo, depende de sua altura. Em um cenário ideal de árvore balanceada, a altura é logarítmica, garantindo o máximo de desempenho. Em um caso degenerado, onde os elementos são inseridos de forma ordenada, a árvore pode se transformar em uma lista ligada, e a complexidade das operações passa a ser linear (O(n)), perdendo sua principal vantagem.

2.3. Desafios no Ensino e Aprendizagem

O aprendizado de árvores torna-se um dos grandes desafios para estudantes de computação justamente pela necessidade de compreender a estrutura em si — como raiz, filhos, nós folha — e a necessidade de compreender as operações que podem ser realizadas nesta estrutura, como inserção, remoção, busca e percursos (pré-ordem, em-ordem e pós-ordem). A abstração necessária para visualizar a manipulação de ponteiros e a reestruturação da árvore durante essas operações é frequentemente citada como uma barreira cognitiva significativa, motivando a busca por ferramentas de visualização que auxiliem nesse processo pedagógico (LAHTINEN; ALA-MUTKA; JÄRVINEN, 2005).

2.4. Teorias de Aprendizagem na Computação

A compreensão de estruturas de dados complexas, como Árvores Binárias de Busca, não depende apenas da correção técnica do conteúdo, mas também dos processos cognitivos envolvidos na assimilação desse conhecimento. Para fundamentar a análise do uso de softwares educativos neste contexto, é necessário compreender três pilares teóricos que dialogam com a visualização de dados e a interação humano-computador: a Teoria da Codificação Dual, a Teoria da Carga Cognitiva e o Sociointeracionismo.

2.5. Teoria da Codificação Dual

Proposta por Allan Paivio em 1986, a Teoria da Codificação Dual (TCD) postula que a cognição humana opera através de dois subsistemas distintos e funcionalmente independentes: o sistema verbal (responsável pelo processamento da linguagem,

texto e som) e o sistema imagético (responsável pelo processamento de objetos visuais e espaciais).

Segundo Paivio (1986), a aprendizagem é potencializada quando a informação é apresentada simultaneamente em ambos os canais, criando conexões referenciais entre eles. No ensino de algoritmos, isso é particularmente relevante. Um código-fonte (verbal/textual) descreve a lógica, mas é abstrato; uma animação da estrutura de dados (imagético) descreve o estado, mas é concreta.

Quando um estudante utiliza um software de visualização, ele não está apenas "vendo" a estrutura, mas ativando o sistema imagético para processar o movimento dos nós da árvore, enquanto ativa o sistema verbal para ler as instruções do algoritmo. A integração desses dois canais facilita a retenção na memória de longo prazo, permitindo a construção de modelos mentais mais robustos do que o uso isolado de texto ou fala.

2.6. Teoria da Carga Cognitiva

Enquanto a Codificação Dual explica como a informação entra, a Teoria da Carga Cognitiva (TCC), desenvolvida por John Sweller no final da década de 1980, foca nas limitações de quanto o cérebro pode processar. A premissa central é que a memória de trabalho humana é limitada e, se sobrecarregada, a aprendizagem é inibida (SWELLER, 1988). Sweller classifica a carga cognitiva em três tipos, essenciais para avaliar ferramentas educacionais:

- **Carga Intrínseca:** Relacionada à complexidade inerente do conteúdo. No caso de Árvores Binárias e Recursividade, a carga intrínseca é naturalmente alta devido ao alto nível de abstração e interatividade dos elementos (SWELLER, 2010).
- **Carga Estranha (Extraneous):** Gerada pela forma como o conteúdo é apresentado. Interfaces confusas, navegação difícil ou excesso de elementos visuais irrelevantes em um software obrigam o aluno a gastar energia mental tentando entender a ferramenta, em vez de entender o conteúdo. O design instrucional deve visar reduzir ao máximo essa carga.
- **Carga Pertinente (Germane):** É o esforço mental voltado efetivamente para a construção de esquemas de aprendizagem.

No contexto deste trabalho, a usabilidade de um software educativo é crítica pois impacta diretamente a Carga Cognitiva Estranha. Se a ferramenta for difícil de usar, a capacidade cognitiva que deveria ser usada para aprender a lógica de inserção na árvore é desperdiçada tentando operar a interface.

2.7. A Mediação no Sociointeracionismo

Por fim, a introdução de tecnologia em sala de aula deve ser observada sob a ótica sociointeracionista de Lev Vygotsky. Para Vygotsky (1991), o aprendizado não é um processo solitário, mas social, mediado por instrumentos e signos.

Nesta perspectiva, o computador ou software educativo atua como um "instrumento cultural" de mediação. Contudo, Vygotsky alerta que o instrumento por si só não garante o desenvolvimento das funções psicológicas superiores. É fundamental o papel do "outro mais capaz" (o professor ou colegas) para atuar na Zona de Desenvolvimento Proximal (ZDP) — a distância entre o que o aluno consegue fazer sozinho e o que consegue fazer com ajuda.

A visualização algorítmica, portanto, funciona como um artefato mediador externo que torna tangível o conceito abstrato. Entretanto, a interpretação correta dessa visualização muitas vezes requer a intervenção docente para guiar a atenção do aluno e evitar interpretações errôneas da animação, transformando a experiência visual em conceito lógico consolidado.

2.8. A Ferramenta *VisuAlgo*

O VisuAlgo é uma plataforma educacional interativa, desenvolvida na Universidade Nacional de Singapura (NUS), projetada para permitir que estudantes visualizem estruturas de dados e algoritmos por meio de animações dinâmicas (HALIM; HALIM, 2013). Diferente de representações estáticas em livros, a ferramenta permite que o usuário execute operações em tempo real — como a inserção, busca e remoção de nós em uma Árvore Binária de Busca — observando a movimentação dos ponteiros e a reestruturação da árvore passo a passo. Além da animação, o software apresenta um pseudocódigo sincronizado que destaca a linha de execução atual, auxiliando na redução da carga cognitiva ao integrar a explicação lógica (verbal) com a representação visual (imagética).

3. TRABALHOS RELACIONADOS

Este capítulo apresenta o estado da arte referente ao uso de tecnologias no ensino de Estruturas de Dados. Inicialmente, descreve-se o protocolo metodológico de Revisão Sistemática da Literatura (RSL) adotado para a seleção e análise dos trabalhos. Em seguida, são apresentadas as ferramentas e estratégias pedagógicas identificadas no levantamento, discutindo seus benefícios e limitações. Por fim, realiza-se uma síntese crítica que evidencia as lacunas de pesquisa que motivam a proposta deste trabalho.

3.1. Protocolo da Revisão Sistemática

O presente trabalho realizou uma revisão sistemática da literatura, conduzida com base nas diretrizes propostas por Kitchenham (2007) para a área de engenharia de *software* e adaptada para o contexto da educação em computação. O seu objetivo foi identificar e analisar estudos publicados que abordam o uso de *softwares* educativos no ensino de estruturas de dados, com ênfase em estruturas não lineares, como as árvores. O foco da análise esteve em verificar quais *softwares* são utilizados, suas abordagens e os métodos de avaliação empregados. Para delimitar o escopo da pesquisa, foi utilizada a estratégia PICO (HIGGINS; THOMAS, 2019), detalhada a seguir:

- **(P) População:** Estudantes de Ciência da Computação e áreas afins.
- **(I) Intervenção:** Uso de *softwares*, ferramentas ou aplicativos educacionais.
- **(C) Comparação:** Métodos tradicionais de ensino (por exemplo, aulas expositivas).
- **(O) Resultado (Outcome):** Melhoria na compreensão, engajamento ou desempenho no aprendizado de estruturas de dados do tipo árvore.

A partir dessa estrutura, foram definidas três Questões de Pesquisa (QPs) para nortear o estudo:

- **QP1:** Quais *softwares* e ferramentas têm sido propostos na literatura para o ensino de estruturas de dados, com foco em árvores?
- **QP2:** Como a eficácia dessas ferramentas foi avaliada nos estudos, considerando os métodos e as métricas empregados?

- **QP3:** Quais são os benefícios e as limitações relatadas do uso dessas ferramentas no processo de ensino-aprendizagem?

A busca pelos estudos foi realizada em cinco bases de dados eletrônicas relevantes para a Ciência da Computação e Educação: ACM *Digital Library*, IEEE *Xplore Digital Library*, *ScienceDirect*, SBC *Open Lib* (SOL) e Periódicos Capes. A string de busca genérica, adaptada para a sintaxe de cada base, foi construída combinando termos relacionados à População, Intervenção e ao contexto educacional, conforme a estrutura:

("Data Structures" OR "Binary Tree") AND
("Education" OR "Teaching" OR "Learning") AND
("Software" OR "Tool" OR "Application").

Para a seleção, foram definidos critérios de inclusão (publicação entre 2018-2024; idiomas inglês ou português; estudos com aplicação de *software*) e exclusão (estudos fora do contexto educacional; revisões de literatura; acesso ao texto completo não disponível).

O processo de seleção foi conduzido por dois revisores independentes e ocorreu em duas fases principais. Na primeira, analisaram-se títulos e resumos, descartando-se os artigos que não atendiam claramente aos critérios. Na segunda fase, os textos completos dos artigos pré-selecionados foram lidos para a aplicação final dos critérios. Eventuais divergências entre os revisores em ambas as fases foram resolvidas por meio de discussão e consenso. Todo o fluxo de identificação, triagem e inclusão dos artigos está detalhado visualmente em um fluxograma, seguindo o modelo PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) (MOHER et al., 2009).

O rigor metodológico de cada estudo incluído foi avaliado com o padrão CASP (*Critical Appraisal Skills Programme*), utilizando-se o *Checklist* para Estudos Qualitativos (CASP, 2024). A escolha dessa ferramenta justifica-se por sua versatilidade e adequação para analisar a diversidade de desenhos de pesquisa encontrados nos artigos, que incluem desde quase-experimentos a relatos de experiência.

O *checklist* do CASP foi aplicado por dois revisores independentes a cada um dos sete estudos para avaliar a validade, a clareza e a aplicabilidade dos achados.

Com base nas respostas (Sim, Não, Não Sei) às questões, foi atribuído um julgamento qualitativo final a cada artigo, classificando sua evidência como de "Alta Qualidade", "Média Qualidade" ou "Baixa Qualidade". Este julgamento foi posteriormente utilizado para ponderar a força das evidências durante a síntese dos resultados. O *checklist* é dividido em três seções, com um total de 10 perguntas:

- Seção A: Validade da pesquisa (Rigor Metodológico)
  - Os objetivos da pesquisa estavam claros?
  - A metodologia qualitativa é apropriada para os objetivos?
  - O desenho da pesquisa foi apropriado para os objetivos (isto é, a adequação do uso e da avaliação da ferramenta)?
  - A estratégia de recrutamento dos participantes foi apropriada?
  - A coleta de dados foi feita de forma a abordar a questão da pesquisa?
  - A relação entre pesquisador e participantes foi considerada?
- Seção B: Resultados da pesquisa
  - A análise dos dados foi suficientemente rigorosa (isto é, a clareza na descrição da análise das respostas dos participantes)?
  - A apresentação dos resultados foi clara?
- Seção C: Utilidade dos resultados (Aplicabilidade)
  - Qual o valor da pesquisa (isto é, a relevância dos achados)?
  - Os resultados podem ser transferidos para outros contextos?

Para cada estudo selecionado, as informações foram extraídas e organizadas em uma planilha eletrônica, contemplando os seguintes itens: autor(es) e ano, objetivos, metodologia de avaliação, resultados (benefícios e limitações), classificação CASP e conclusões. A síntese dos resultados foi então realizada de forma narrativa, agrupando os achados de acordo com as Questões de Pesquisa.

3.2. Ferramentas e Estratégias Identificadas

A busca inicial nas bases de dados identificou um total de 1.066 artigos. Após a aplicação progressiva dos critérios de inclusão e exclusão, este número foi reduzido a 7 estudos elegíveis para a análise final. O processo completo de seleção, detalhando as etapas de identificação, triagem e inclusão, é apresentado no fluxograma da Figura 4.

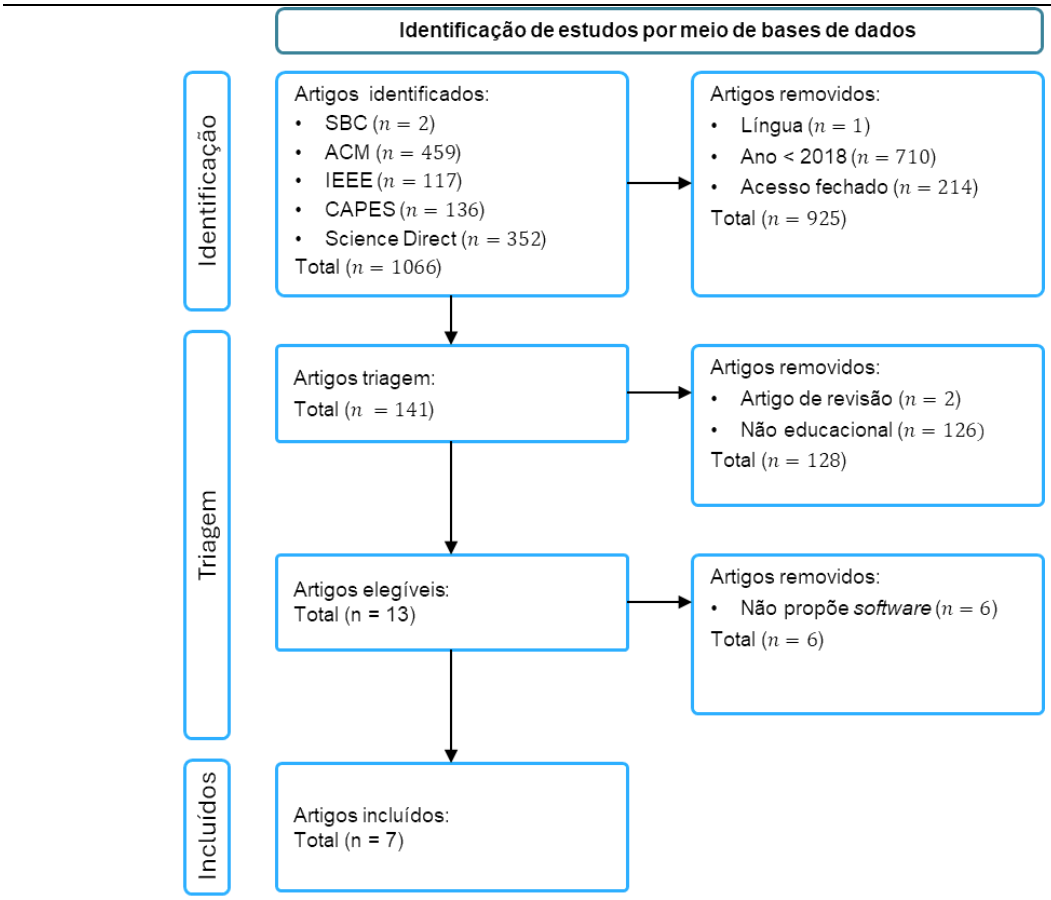


Figura 4 - Fluxograma de seleção de artigos

Fonte: Elaborado pelo autor (2026)

Os estudos selecionados empregaram ferramentas variadas, algumas preexistentes e outras desenvolvidas pelos próprios autores. Em sua maioria, as abordagens foram similares, focando na visualização das estruturas de dados para mitigar a dificuldade de abstração. A Tabela 1 sintetiza as informações extraídas de cada artigo, incluindo objetivos, resultados e conclusões.

Tabela 1 - Características dos estudos incluídos pela revisão

(ROJAS-SALAZAR; RAMÍREZ-ALFARO; HAÁHR, 2020)	
Objetivos	Apresentar a ferramenta DS-Hacker para o ensino de árvores binárias de busca (BST), utilizando analogias com jogos para introduzir conceitos e promover o conhecimento prévio dos alunos.
Resultados	O DS-Hacker é um jogo 3D de ação-aventura para PC com cinco níveis, que cobrem desde a estrutura básica da BST até o algoritmo de busca. Cada nível possui missões que incorporam as atividades de aprendizado.
Conclusão	A ferramenta utiliza analogias e um gênero de jogo familiar para conectar o novo conteúdo ao conhecimento prévio dos alunos. O jogo é projetado para promover o aprendizado ativo, mas o projeto ainda se encontra em andamento, com a avaliação experimental pendente.
Nota CASP	3/10 (“Baixa Qualidade”)

(BALBINO DE PAULA et al., 2023)	
Objetivos	Analisar os benefícios e desafios do uso do ChatGPT como ferramenta educacional para o aprendizado de árvores binárias, investigando sua efetividade como suporte ao ensino.
Resultados	Alunos relataram problemas como códigos incorretos. Contudo, os benefícios superaram as deficiências. O professor observou melhora no entendimento e na participação dos alunos que usaram a ferramenta, mas também uma dependência para a implementação de códigos. Mais de 80% dos alunos consideraram o ChatGPT útil e pretendem continuar a usá-lo.
Conclusão	O ChatGPT pode ser um aliado educacional, mas necessita de aprimoramento. O acompanhamento do professor é fundamental para direcionar o aprendizado e corrigir informações incorretas ou incompletas fornecidas pela ferramenta.
Nota CASP	7/10 (“Média Qualidade”)
(MCQUAIGUE et al., 2018)	
Objetivos	Construir módulos de aprendizado visuais e interativos para o ensino de estruturas de dados. Desenvolver um sistema de análise e visualização para fornecer *feedback* instantâneo aos instrutores.
Resultados	Foi desenvolvido um protótipo com módulos para BSTs e listas ligadas, integrado à infraestrutura do OpenDSA. Os exercícios possuem alta variabilidade para evitar plágio. O sistema inclui um painel de análise visual que utiliza biclusterização para identificar padrões de desempenho.
Conclusão	O artigo apresenta módulos de aprendizado inovadores que integram avaliação e instrução em um ambiente interativo. O sistema de análise visa ajudar instrutores a identificar alunos em risco. A implementação é um protótipo que necessita de mais desenvolvimento e estudos com usuários.
Nota CASP	4/10 (“Baixa Qualidade”)
(DICHEVA; HODGE, 2018)	
Objetivos	Apresentar o jogo educacional "*The Stack Game*" para facilitar a compreensão da estrutura de dados de pilha e avaliar a viabilidade da aprendizagem baseada em jogos.
Resultados	A avaliação indicou ganhos de aprendizado estatisticamente significativos. As notas pós-jogo foram significativamente mais altas que as pré-jogo, com um grande tamanho de efeito (> 0.80). Alunos demonstraram atitude positiva: 96% concordaram que jogos ajudam a esclarecer conceitos e 92% manifestaram interesse em jogos similares.
Conclusão	O "*The Stack Game*" mostrou-se uma ferramenta de aprendizado eficaz para o conceito de pilha. A maioria dos alunos reagiu positivamente e demonstrou interesse em abordagens similares para outros tópicos de estruturas de dados.
Nota CASP	8/10 (“Alta Qualidade”)
(NATHASYA et al., 2019)	
Objetivos	Integrar ferramentas de visualização de programa e de algoritmos na ferramenta DS-PITON, para auxiliar os alunos a compreenderem a implementação de estruturas de dados.
Resultados	A ferramenta auxiliou os alunos a obterem melhores notas e a terminarem as avaliações mais rapidamente. O efeito foi mais proeminente em alunos de ritmo moderado, enquanto para alunos de ritmo lento não foram observadas mudanças significativas.
Conclusão	Os alunos perceberam a ferramenta como útil para o aprendizado, e ela demonstrou potencial para melhorar as notas.
Nota CASP	8/10 (“Alta Qualidade”)

(RAVENSCROFT, 2018)	
Objetivos	Apresentar a ferramenta DDS (baseada em HTML5 e JS) para modelar estruturas de dados dinâmicas, substituindo o ciclo de desenhar-apagar-redesenhar do ensino tradicional.
Resultados	A ferramenta foi criada para manipular a visualização de estruturas, não para executar algoritmos. Seu uso otimizou o tempo de aula, aumentou a motivação e facilitou a demonstração de implementações. A capacidade de restaurar estados anteriores do modelo auxiliou na resposta a dúvidas dos alunos.
Conclusão	A ferramenta demonstrou ser fácil de usar e eficaz para simplificar o ensino de estruturas de dados. Como limitações, foram apontadas a ausência de uma funcionalidade para "desfazer" e de um modelo para a recursão.
Nota CASP	5/10 (“Média Qualidade”)
(TERESCO, 2018)	
Objetivos	Descrever atividades de laboratório que utilizam dados de grafos do mundo real (rodovias) para ensinar algoritmos de travessia e árvores de abrangência de forma mais envolvente.
Resultados	O uso de visualizações ajudou 88,9% dos alunos a entenderem os algoritmos. A conexão com dados do mundo real tornou o material mais interessante para 77,8% dos alunos. Uma tarefa de programação demonstrou que os 4 algoritmos abordados são programaticamente quase idênticos.
Conclusão	Os dados de grafos do mundo real e as visualizações do projeto METAL são adequados e motivadores para o ensino dos algoritmos abordados. O projeto é um recurso livremente disponível para educadores.
Nota CASP	7/10 (“Média Qualidade”)

Fonte: Elaborado pelo autor (2026)

Pergunta 1 - Quais são os softwares utilizados para ensino de estruturas de dados?

A análise dos artigos selecionados revelou que não houve repetição das ferramentas de *software* utilizadas; cada estudo empregou uma solução distinta, seja por meio de desenvolvimento próprio ou da adoção de uma ferramenta preexistente.

Três dos estudos analisados utilizaram ou desenvolveram módulos para ferramentas já existentes (BALBINO DE PAULA et al., 2023; MCQUAIGUE et al., 2018; TERESCO, 2018). A primeira abordagem consistiu no uso do ChatGPT como ferramenta de suporte para sanar dúvidas dos alunos sobre o conteúdo (BALBINO DE PAULA et al., 2023). A segunda envolveu a criação de módulos de estruturas de dados para a plataforma OpenDSA, um sistema de livro didático interativo (MCQUAIGUE et al., 2018). A terceira utilizou as ferramentas do projeto METAL, incluindo o *Highway Data Examiner* (HDX), para a visualização de grafos com base em dados reais de rodovias (TERESCO, 2018).

Os quatro estudos restantes apresentaram *softwares* desenvolvidos pelos próprios autores, que variaram de jogos educacionais a ferramentas de visualização interativa (ROJAS-SALAZAR; RAMÍREZ-ALFARO; HAÁHR, 2020; DICHEVA; HODGE, 2018; NATHASYA et al., 2019; RAVENSCROFT, 2018). As soluções desenvolvidas foram:

- **DS-Hacker:** Um jogo 3D de ação-aventura para o ensino de Árvores Binárias de Busca (ROJAS-SALAZAR; RAMÍREZ-ALFARO; HAÁHR, 2020).
- **The Stack Game:** Um jogo focado no ensino da estrutura de dados de pilha, abordando sua conceituação, aplicação e implementação (DICHEVA; HODGE, 2018).
- **DS-PITON:** Uma ferramenta que integra a visualização de programa (PV) com a visualização de algoritmos (AV) para facilitar a compreensão da implementação de estruturas de dados (NATHASYA et al., 2019).
- **Dynamic Data Structures (DDS):** Um sistema interativo baseado em HTML5 e JavaScript para modelar graficamente listas ligadas e árvores binárias (RAVENSCROFT, 2018).

Ao fim da análise, a pesquisa mostrou uma variedade de abordagens. Algumas ferramentas, como o DS-Hacker e o *The Stack Game* (ROJAS-SALAZAR; RAMÍREZ-ALFARO; HAÁHR, 2020; DICHEVA; HODGE, 2018), foram desenvolvidas para o aprendizado ativo através de jogos. Outras, como o DS-PITON e o DDS (NATHASYA et al., 2019; RAVENSCROFT, 2018), focaram na visualização e modelagem interativa. Também foram utilizadas ferramentas já existentes, como o ChatGPT (BALBINO DE PAULA et al., 2023) para suporte a dúvidas e o METAL para visualização de grafos em cenários do mundo real (TERESCO, 2018).

Em síntese, a análise dos artigos revelou uma diversidade de abordagens. Duas categorias principais de *software* próprio emergiram: ferramentas de aprendizado ativo baseadas em jogos (DS-Hacker e The Stack Game) e sistemas focados em visualização e modelagem interativa (DS-PITON e DDS). Adicionalmente, foram identificados usos de ferramentas preexistentes adaptadas ao contexto educacional, como o ChatGPT para suporte a dúvidas e o projeto METAL para contextualização com dados do mundo real.

Pergunta 2 - Quais metodologias utilizadas para avaliar a eficácia?

As metodologias de avaliação de eficácia variaram consideravelmente entre os sete estudos selecionados. Foi possível agrupá-los em três categorias: estudos sem avaliação empírica, estudos com avaliação limitada e estudos com avaliação robusta.

Três dos sete artigos não apresentaram uma avaliação empírica de eficácia por diferentes razões. O primeiro descreveu apenas o *design* do protótipo (MCQUAIGUE et al., 2018), o segundo estava em andamento no momento da publicação (ROJAS-SALAZAR; RAMÍREZ-ALFARO; HAÁHR, 2020), e o terceiro limitou-se a um relato de experiência em sala de aula (RAVENSCROFT, 2018).

Um estudo realizou uma avaliação empírica, porém com uma amostra considerada pequena (n = 36), o que pode limitar a generalização dos resultados (TERESCO, 2018). A metodologia consistiu em uma pesquisa pós-curso, na qual foi aplicado um questionário com perguntas em escala Likert de 7 pontos.

O estudo de Balbino de Paula et al. (2023) avaliou o uso do ChatGPT no aprendizado de árvores binárias em uma turma de Estrutura de Dados com 27 alunos. A metodologia envolveu a criação de um guia de *prompts* para os estudantes utilizarem a ferramenta ao longo de três semanas. A coleta de dados foi realizada por meio de um questionário *online*, respondido por 9 participantes, contendo 10 afirmações em escala Likert e três questões subjetivas, além de uma entrevista com o professor para obter sua percepção sobre o método.

Os resultados indicaram uma percepção mista. Apesar de mais da metade dos alunos relatarem dificuldades e a ferramenta gerar códigos incorretos, a maioria (mais de 80%) manifestou interesse em continuar utilizando o ChatGPT para outros tópicos de programação. A entrevista com o professor corroborou esses pontos, destacando um aumento considerável no engajamento e na compreensão teórica dos alunos sobre árvores binárias. Contudo, essa melhora conceitual não se refletiu na habilidade dos alunos de implementarem o código do zero, sugerindo a criação de uma dependência da ferramenta para direcionar suas atividades.

A abordagem de Dicheva e Hodge (2018) consistiu em um estudo empírico com 29 alunos de um curso de Estrutura de Dados para avaliar o potencial de um jogo educativo sobre o tema de pilhas. A metodologia envolveu a aplicação de pré e pós-

testes para medir o ganho de conhecimento dos alunos após jogarem o "*Stack Game*" em duas sessões de laboratório. A avaliação foi complementada por uma análise dos logs de jogabilidade e por um questionário qualitativo *online* para coletar o *feedback* dos participantes sobre a ferramenta.

A pontuação média dos alunos saltou de 17,83 para 31,66 (de um total de 40 pontos). O Teste t confirmou uma diferença estatisticamente significativa (p-valor <0,05), com um tamanho de efeito (*effect size*) geral de 1,0320, considerado grande. A análise dos *logs* de jogo indicou que 72% dos alunos completaram as duas primeiras partes do *game* e que a conclusão das atividades se correlacionou com um melhor desempenho no pós-teste. Adicionalmente, a recepção dos estudantes foi extremamente positiva: 96% concordaram que jogos educativos ajudam a esclarecer conceitos e 92% expressaram o desejo de utilizar jogos semelhantes para outros tópicos da disciplina

Por fim, o estudo de Nathasya et al. (2019) realizou um quase-experimento, comparando o aprendizado com a ferramenta DS-PITON *versus* o uso de livros didáticos. A avaliação considerou o tempo de conclusão das tarefas e a pontuação final de dois grupos de 15 alunos cada: um composto por estudantes de ritmo moderado e outro por estudantes de ritmo lento. Para medir a significância estatística da melhora, foi empregado um Teste t. A metodologia foi complementada por um questionário com 11 perguntas em escala Likert de 5 pontos e uma questão aberta para coletar as perspectivas dos alunos.

Os resultados para os alunos de ritmo moderado mostraram que o DS-PITON levou a pontuações mais altas em ambas as avaliações, com melhorias estatisticamente significativas (p-valores <0,05). Além disso, a ferramenta demonstrou ser mais eficiente em termos de tempo, pois os alunos concluíram as tarefas significativamente mais rápido ao usá-la, com reduções também estatisticamente significativas (p-valores <0,05).

Para os alunos de ritmo lento, o uso da ferramenta também resultou em pontuações significativamente maiores nos três experimentos realizados (p-valores <0,05). No entanto, ao contrário do outro grupo, o DS-PITON não reduziu o tempo de conclusão das tarefas, podendo até aumentá-lo de forma estatisticamente significativa em um dos casos. A pesquisa de opinião corroborou a utilidade da ferramenta, com

todas as perguntas recebendo uma pontuação média superior a 4 (equivalente a "concordo"), indicando que os alunos acreditam que o DS-PITON os ajuda a compreender o material.

Pergunta 3 - Quais limitações e benefícios do software?

A análise dos estudos selecionados permitiu identificar um conjunto distinto de benefícios e limitações para cada uma das sete ferramentas propostas. Para apresentar esses achados de forma clara e integrada, os resultados de cada estudo são detalhados individualmente a seguir.

Estudo de Rojas-Salazar et al. (2020): Ferramenta DS-Hacker

A principal vantagem da ferramenta é a promoção do aprendizado ativo por meio do ciclo de aprendizagem experiencial de Kolb(1984). Adicionalmente, o jogo utiliza analogias para conectar conceitos abstratos a elementos familiares aos alunos, como labirintos e portais, e emprega um gênero popular (ação-aventura) para reduzir a curva de aprendizado de sua mecânica. Contudo, as limitações estão relacionadas à sua natureza como jogo. Foi apontado que elementos como músicas e efeitos sonoros podem servir como distração, enquanto o desempenho pode ser prejudicado em computadores com *hardware* insuficiente. Outro desafio é a possível dificuldade de alunos que não possuem familiaridade com jogos.

Estudo de Balbino de Paula et al. (2023): Ferramenta ChatGPT

Os benefícios do ChatGPT centram-se na sua capacidade de atuar como ferramenta de apoio, sendo de fácil uso e compreensão. O estudo sugere que ele pode aumentar a motivação ao fornecer um ambiente de interação familiar para os alunos sanarem dúvidas de forma eficiente. Por outro lado, foram observadas limitações significativas, como o risco de a ferramenta fornecer informações ou códigos incorretos. Paula et al. (2024) alertam ainda para a possibilidade de os alunos desenvolverem dependência da ferramenta, a falta de transparência do modelo e o potencial de reproduzir vieses, desafios que exigem cautela em seu uso pedagógico.

Estudo de Mcquaigue et al. (2018): Ferramenta OpenDSA

A proposta deste estudo se destaca pela integração entre aprendizado e avaliação em um ambiente interativo. Suas vantagens incluem módulos visuais que promovem o engajamento, alta variabilidade nos exercícios para garantir a integridade

acadêmica e ferramentas de análise que auxiliam os instrutores a identificar alunos em risco. As limitações reportadas derivam do fato de o projeto ser um protótipo no momento da publicação, que ainda não estava totalmente integrado a um Ambiente Virtual de Aprendizagem (AVA) e carecia de um estudo empírico com usuários para avaliar seu impacto real no aprendizado.

Estudo de Dicheva e Hodge (2018): Ferramenta *The Stack Game*

A avaliação do jogo demonstrou resultados positivos, com destaque para ganhos de aprendizado estatisticamente significativos. A maioria dos alunos manifestou uma atitude positiva em relação à ferramenta, e a análise dos logs de jogabilidade sugeriu que o engajamento nas primeiras partes do jogo se correlacionou com melhores notas no pós-teste. As principais limitações foram de ordem metodológica e de conteúdo: o estudo foi conduzido com uma turma pequena, o que dificulta a generalização dos resultados. Adicionalmente, não foi possível avaliar o ganho de conhecimento na terceira parte do jogo (implementação) devido à falta de tempo e ao fato de suas instruções terem sido consideradas menos claras pelos participantes.

Estudo de Nathasya et al. (2019): Ferramenta DS-PITON

A ferramenta demonstrou ser particularmente eficaz para diferentes perfis de alunos, resultando em melhora nas notas tanto para estudantes de ritmo lento quanto moderado. Para este último grupo, observou-se também um aumento da eficiência, com a conclusão mais rápida das avaliações. Os autores também reportaram que a ferramenta funcionou corretamente, sem *bugs* durante os testes. A única limitação apontada foi um efeito adverso para os alunos de ritmo lento, para os quais a ferramenta pareceu aumentar o tempo de conclusão das avaliações, apesar da melhora nas notas.

Estudo de Ravenscroft (2018): Ferramenta DDS

Este estudo reportou que a ferramenta DDS foi eficaz para otimizar o tempo em sala de aula, principalmente por eliminar o ciclo de "desenhar-apagar-redesenhar" no quadro. Sua *interface* foi considerada simples e com baixa curva de aprendizado, o que facilitou a demonstração de implementações corretas e incorretas de operações em estruturas de dados. As limitações identificadas foram de ordem funcional e

técnica, pois a ferramenta não possui um modelo para a recursão, não oferece um recurso de "desfazer" ações e não permite a seleção de subárvores inteiras.

Estudo de Teresco (2018): Ferramenta Projeto METAL (HDX)

A principal vantagem do projeto METAL é o uso de dados do mundo real (sistemas de rodovias) para aumentar o engajamento dos alunos, permitindo a visualização de diversos algoritmos de grafos em mapas reais. O sistema destaca-se também por ser um recurso gratuito e disponível para outros educadores. As dificuldades reportadas foram a limitação em realizar um estudo empírico de eficácia devido ao tamanho reduzido das turmas (menos de 50 alunos) e a dificuldade de visualização interativa no HDX quando se trabalha com grafos muito grandes.

3.3. Síntese e Lacunas de Pesquisa

A análise da literatura permite concluir que a natureza abstrata das estruturas de dados, especialmente as árvores, impõe barreiras cognitivas que justificam a busca por ferramentas de apoio pedagógico. A revisão dos trabalhos relacionados demonstrou que estratégias de visualização interativa e gamificação, quando avaliadas por metodologias robustas, mostram-se eficazes para elevar o engajamento e o desempenho discente.

Entretanto, as soluções existentes apresentam limitações importantes. Observou-se que muitas ferramentas falham em se adaptar a diferentes ritmos de aprendizagem — como evidenciado nas dificuldades de alunos lentos com o DS-PITON — ou carecem de mecanismos que garantam a autonomia do estudante sem criar dependência tecnológica. Além disso, a literatura aponta para a necessidade de um alinhamento rigoroso entre o *software* e os objetivos pedagógicos, sob pena de a tecnologia tornar-se um obstáculo em vez de um facilitador.

Diante desse cenário, nota-se uma lacuna para pesquisas que não apenas proponham o uso de *softwares* educativos, mas que validem sua eficácia através de estudos comparativos controlados. O presente trabalho busca inserir-se nessa lacuna, propondo uma análise empírica sobre o impacto de uma ferramenta de visualização (*VisuAlgo*) no ensino de Árvores Binárias de Busca, considerando tanto o desempenho acadêmico quanto a percepção de usabilidade e satisfação dos estudantes.

4. METODOLOGIA

Esta seção detalha o arcabouço metodológico utilizado para conduzir a pesquisa, abrangendo o delineamento do estudo, os participantes, os instrumentos, os procedimentos de coleta e análise de dados, bem como as considerações éticas e as potenciais ameaças à validade do estudo.

4.1. Delineamento do Estudo

O presente estudo apresenta um delineamento do tipo experimental, utilizando uma abordagem de métodos mistos para coletar e analisar dados quantitativos e qualitativos. O desenho experimental adotado será o de pré-teste e pós-teste com grupo de controle, com alocação aleatória dos participantes, visando estabelecer relações de causa e efeito entre a intervenção pedagógica e os resultados de aprendizagem.

4.2. Participantes e Contexto

A amostra foi composta por discentes (n=11) de uma turma regular da disciplina de Estrutura de Dados II do curso de Ciência da Computação do Instituto Federal de Sergipe (IFS) – Campus Itabaiana, no ano de 2025. Como critério para seleção dos participantes, foi levado em conta que o participante tenha participado da aula sobre árvores binárias ministrada no curso pelo professor regular da disciplina. A abordagem para os alunos foi realizada na aula posterior à aula sobre árvores binárias.

4.3. Instrumentos de Coleta de Dados

Para o trabalho foi desenvolvido o Questionário de Desempenho de forma autoral, e além deste, foram utilizados também os instrumentos *System Usability Scale*(SUS) e *Net Promoter Score*(NPS).

4.4. Questionário de Desempenho (Pré e Pós-teste)

Instrumento com questões objetivas sobre a estrutura de dados de árvore binária de busca, para avaliar a compreensão conceitual e prática dos alunos (vide Apêndice A). O mesmo questionário será utilizado em ambos os momentos de testagem. Esse instrumento de avaliação foi estruturado estrategicamente para mensurar três dimensões cognitivas distintas do aprendizado sobre Árvores Binárias de Busca:

- **Conceitos Estruturais e Terminologia (Fundamentos):** Visa avaliar a capacidade de identificar elementos estáticos (raiz, folhas, pais), exigindo processamento visual. Esta dimensão dialoga com o subsistema imagético da Teoria da Codificação Dual (PAIVIO, 1986). (Questões 1 a 4).
- **Algoritmos de Percurso (Lógica Recursiva):** Objetiva testar a compreensão da ordem de visitação e execução recursiva (Pré-ordem, Em-ordem, Pós-ordem). Trata-se de uma tarefa de alta abstração que, segundo a ótica Sociointeracionista, geralmente demanda mediação. (Questões 5 a 7).
- **Operações Dinâmicas e Regras de Negócio:** Foca na aplicação prática das propriedades da Árvore Binária de Busca, exigindo que o aluno simule mentalmente as alterações na estrutura causadas por inserções, buscas, identificação de sucessores/antecessores e, principalmente, os casos complexos de remoção. (Questões 8 a 14).

4.5. System Usability Scale (SUS)

Um questionário padronizado de 10 itens, com respostas em escala Likert de 5 pontos, utilizado para avaliar a usabilidade percebida do *software VisuAlgo* (vide Apêndice B). O SUS gera um escore global de usabilidade que varia de 0 a 100 (LOURENÇO, 2022). É importante ressaltar que este escore não representa uma porcentagem, mas sim uma escala de percentil. Para a interpretação qualitativa dos resultados, este trabalho adota a escala de adjetivos proposta por Bangor, Kortum e Miller (2009), que correlaciona a pontuação numérica com níveis de aceitabilidade:

- **0 a 50 (Inaceitável):** Classificação 'Ruim' ou 'Pobre', indicando graves problemas de usabilidade que impedem a realização de tarefas.
- **50 a 70 (Marginal):** Classificação 'OK' ou 'Regular', indicando que o sistema é utilizável, mas exige esforço cognitivo e melhorias na interface.
- **70 a 85 (Aceitável):** Classificação 'Bom', sugerindo uma interface fluida e intuitiva para a maioria dos usuários.
- **85 a 100 (Excelente):** Classificação 'Best Imaginable', reservada a sistemas com usabilidade excepcional e sem fricção.

4.6. Net Promoter Score (NPS)

Um instrumento de uma única questão ("Em uma escala de 0 a 10, o quanto você recomendaria esta ferramenta a um colega?") que mede a lealdade e a satisfação do usuário (vide Apêndice B). As respostas classificam os usuários em "Promotores", "Passivos" e "Detratores" (REICHHELD, 2006). Os usuários “Detratores” são com nota de 0 a 6, “Passivos” com nota 7 ou 8, e os “Promotores” com nota 9 ou 10.

4.7. Procedimentos Metodológicos

A coleta de dados foi estruturada em quatro etapas principais, envolvendo a aplicação de testes de desempenho e questionários de percepção. A Figura 5 apresenta a sequência lógica desses procedimentos, detalhando a divisão entre os grupos Controle e Experimental.

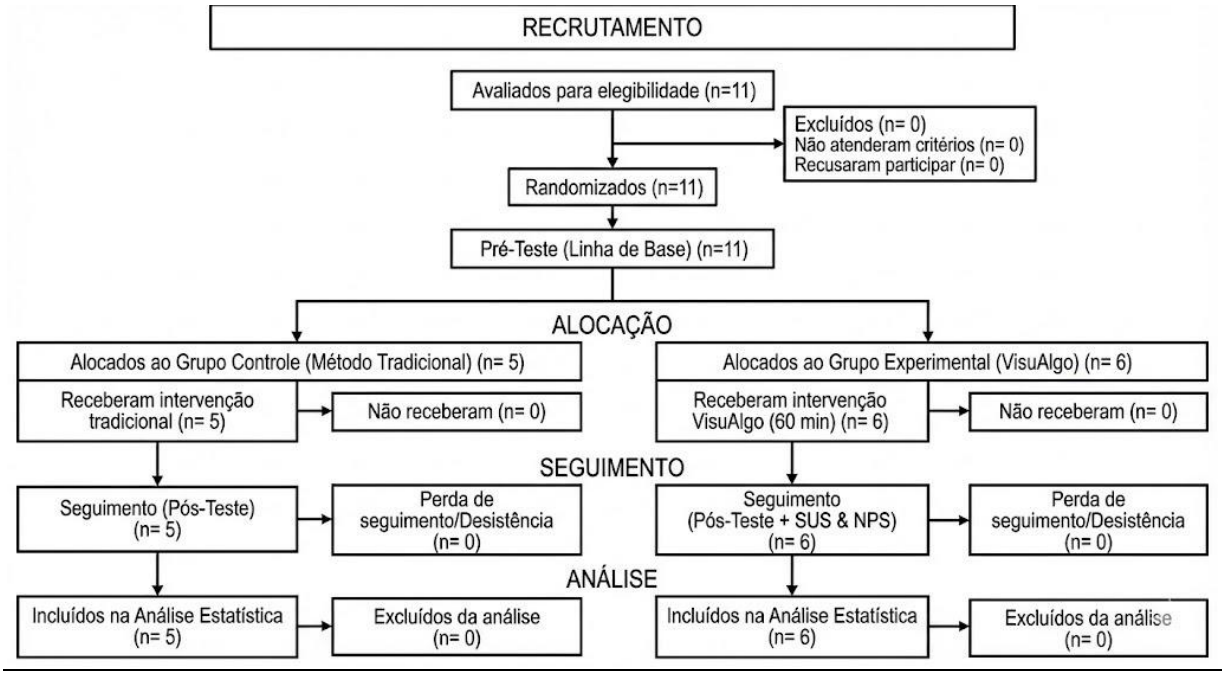


Figura 5 - Fluxograma das etapas da pesquisa experimental

Fonte: Elaborado pelo autor (2026)

- **Etapa 1 (Pré-teste):** Inicialmente, o questionário de desempenho foi aplicado a todos os participantes para mensurar e registrar o conhecimento prévio sobre o tema.
- **Etapa 2 (Randomização e Intervenção):** Após a aula expositiva padrão sobre árvores binárias, os participantes foram aleatoriamente alocados em um dos dois grupos por meio de um sorteio.
  - **Grupo Controle (GC):** Foi direcionado para uma atividade de reforço, na qual resolveram uma lista de exercícios sobre o tema utilizando a abordagem tradicional (lápis, papel e discussão conceitual).
  - **Grupo Experimental (GE):** Foi direcionado para a utilização do *software* *VisuAlgo* para realizar atividades de simulação, exploração interativa e resolução dos mesmos exercícios propostos ao GC.
- **Etapa 3 (Pós-teste):** Imediatamente após a conclusão da atividade de intervenção, ambos os grupos responderam novamente ao questionário de desempenho (pós-teste).
- **Etapa 4 (Avaliação da Ferramenta):** Por fim, o Grupo Experimental respondeu aos questionários *System Usability Scale* (SUS) e *Net Promoter Score* (NPS) para avaliar a usabilidade e a satisfação com a ferramenta *VisuAlgo*.

4.8. Análise dos Dados

A análise quantitativa dos dados foi realizada utilizando a linguagem *Python* (bibliotecas Pandas e *SciPy*). Devido ao tamanho reduzido da amostra (n=11, sendo 5 no Grupo Controle e 6 no Grupo Experimental), optou-se pela utilização de estatística inferencial baseada em reamostragem (*Bootstrap*), método robusto que não depende da premissa de normalidade dos dados, comum em amostras pequenas (HAUKOOS; LEWIS, 2005).

4.9. Tratamento e Análise Descritiva dos Dados

Inicialmente, os dados coletados foram organizados em uma base de dados, na qual os participantes foram identificados por códigos numéricos para garantir o anonimato. Não houve descarte de participantes por dados incompletos. Em seguida, foram calculadas estatísticas descritivas (média, mediana, desvio-padrão, mínimo e máximo) para os escores de desempenho em cada grupo (Controle e Experimental) e em cada momento (pré-teste e pós-teste). A distribuição dos dados foi visualizada por meio de gráficos como *boxplots* e histogramas para uma compreensão inicial de seus padrões.

Para comparar o desempenho entre os grupos (pré e pós-teste), utilizou-se o Teste T para amostras independentes com aplicação de *Bootstrap* (10.000 reamostragens) para estimar os Intervalos de Confiança (IC 95%) da diferença das médias (HAUKOOS; LEWIS, 2005). O tamanho do efeito foi mensurado através do d de Cohen (COHEN, 1988), permitindo avaliar a magnitude do impacto da intervenção pedagógica independentemente do tamanho da amostra.

Adicionalmente, conduziu-se uma análise segmentada por nível de complexidade cognitiva (questões de busca, percurso, inserção e remoção) para identificar a eficácia da ferramenta em diferentes tópicos.

4.10. Análise dos Dados de Percepção

Os dados dos instrumentos SUS e NPS, aplicados ao Grupo Experimental, foram analisados da seguinte forma:

- ***System Usability Scale* (SUS):** O escore final do SUS para cada participante foi calculado seguindo o procedimento padrão: para os itens ímpares, subtrai-se 1 da resposta; para os itens pares, subtrai-se a resposta de 5. A soma de todos os valores convertidos é então multiplicada por 2,5, gerando um escore final de 0 a 100. Será calculada a média do escore SUS do grupo para classificar a usabilidade da ferramenta (e.g., acima de 68 é considerado acima da média).
- ***Net Promoter Score* (NPS):** Os participantes foram classificados com base em suas notas: Promotores (notas 9 - 10), Passivos (notas 7 - 8) e Detratores (notas 0 - 6). O escore NPS final foi calculado pela fórmula: **NPS = (% de Promotores) - (% de Detratores).** O resultado foi interpretado para avaliar o nível de satisfação geral com a ferramenta.

4.11. Ameaças à Validade

Este estudo reconhece e endereça potenciais ameaças à sua validade, que são organizadas em duas categorias: interna e externa. A validade interna refere-se ao grau de confiança de que a intervenção (o uso do *software VisuAlgo*) foi, de fato, a causa da mudança observada no desempenho dos alunos. Para este estudo foram identificadas as seguintes ameaças à validade interna:

- **História e Maturação:** Acontecimentos externos ou o amadurecimento natural dos alunos entre o pré e o pós-teste são ameaças neutralizadas pelo delineamento do estudo. Como ambos os grupos (Controle e Experimental) estão sujeitos a esses mesmos fatores ao longo do período, qualquer efeito é "suavizado" na comparação final entre eles.
- **Efeito de Teste:** A possibilidade de os alunos aprenderem com o pré-teste, influenciando seu desempenho no pós-teste, também é controlada. Como ambos os grupos realizam o pré-teste, o efeito da testagem é distribuído igualmente, não favorecendo um grupo em detrimento do outro. A não divulgação dos gabaritos entre os testes foi uma medida adicional para fortalecer esse controle.
- **Contaminação ou Difusão do Tratamento:** Esta é uma ameaça relevante para o presente estudo, pois os participantes de ambos os grupos pertencem à mesma turma. Existe o risco de que um aluno do Grupo Experimental compartilhe a experiência ou mostre o *software* a um colega do Grupo Controle. Para mitigar esse

risco, a intervenção foi realizada em um único encontro, em ambiente controlado, e os participantes foram instruídos a focar exclusivamente em suas tarefas designadas.

A validade externa refere-se à possibilidade de generalizar os resultados deste estudo para outras populações, contextos e tempos. Para este estudo foram identificadas as seguintes ameaças à validade externa:

- **Características da Amostra:** Esta é a principal ameaça à validade externa. A amostra, embora englobe toda uma turma, é uma **amostra de conveniência**, composta por alunos de um curso e instituição específicos (Ciência da Computação, IFS - Campus Itabaiana). Portanto, a generalização dos resultados para estudantes de outras universidades ou com perfis diferentes deve ser feita com cautela.
- **Tamanho da Amostra:** O tamanho reduzido da amostra, característico de estudos com uma única turma, pode limitar o poder estatístico para detectar efeitos menores e a estabilidade dos resultados. A utilização de técnicas como o *bootstrap* na análise de dados visa conferir maior robustez às conclusões, mesmo com uma amostra pequena.

4.12. Aspectos Éticos

O presente estudo adere estritamente às diretrizes éticas para pesquisa com seres humanos, conforme a Resolução CNS nº 466/12 e nº 510/16. O projeto foi submetido à apreciação do Comitê de Ética em Pesquisa (CEP) do Instituto Federal de Sergipe para aprovação formal antes do início da coleta de dados, e foi aprovado com o Certificado de Apresentação para Apreciação Ética (CAAE) 90566225.2.0000.8042.

A participação na pesquisa foi realizada de maneira voluntária e condicionada à assinatura do **Termo de Consentimento Livre e Esclarecido (TCLE)**, que detalhou todos os objetivos, procedimentos, riscos e benefícios, assegurando o direito do participante de desistir a qualquer momento, sem qualquer ônus ou prejuízo acadêmico.

4.13. Ambiente Experimental e Protocolo de Uso do *VisuAlgo*

A intervenção com o Grupo Experimental foi conduzida em ambiente controlado, nas dependências de um laboratório de informática do IFS – Campus Itabaiana. Quanto à infraestrutura física, adotou-se uma abordagem flexível: os participantes tiveram à disposição os *desktops* da instituição, mas foi facultada a utilização de computadores portáteis (*notebooks*) próprios, conforme a preferência de cada discente. Essa medida visou garantir que o aluno utilizasse o dispositivo com o qual possuía maior familiaridade e conforto ergonômico, minimizando variáveis externas que pudessem interferir na usabilidade.

A sessão de uso teve duração total de 60 minutos. A estratégia pedagógica adotada caracterizou-se pela exploração livre e não diretiva. Diferentemente de treinamentos baseados em tutoriais passo a passo, não foi fornecido aos alunos nenhum roteiro prévio ou manual de instruções sobre como operar o *software*.

O protocolo inicial limitou-se à apresentação da interface de boas-vindas do *VisuAlgo* e ao direcionamento para o módulo específico de "Árvores Binárias de Busca" (BST). A partir deste ponto, os estudantes foram instruídos a interagir com a ferramenta de forma autônoma, descobrindo suas funcionalidades (inserção, busca, remoção e animação) por tentativa e erro ou inferência, simultaneamente à resolução do questionário de desempenho. Esse formato teve o objetivo de simular um cenário real de autoaprendizagem e verificar a intuitividade da *interface* sob demanda cognitiva imediata.

4.14. Controle de Variáveis e Mediação Pedagógica

Para assegurar a equidade das condições experimentais e isolar o efeito da variável independente (uso do *software*), foram adotados rigorosos controles de tempo e ambiente.

O Grupo Controle (GC) realizou a atividade no mesmo laboratório e simultaneamente ao Grupo Experimental, porém posicionado em ilhas de trabalho fisicamente distintas para evitar a contaminação visual da intervenção (visualização das telas do *software*). O tempo dedicado à resolução dos exercícios foi padronizado em 60 minutos para ambos os grupos, garantindo a equivalência de tempo na tarefa.

A mediação pedagógica e o esclarecimento de dúvidas foram realizados pelo mesmo pesquisador para ambos os grupos. A atuação do instrutor restringiu-se a sanar dúvidas sobre o enunciado das questões ou problemas técnicos, mantendo-se neutra em relação à resolução dos problemas lógicos, a fim de não influenciar o desempenho cognitivo dos participantes e evitar o viés do instrutor.

Enquanto o Grupo Experimental utilizava o *VisuAlgo*, o Grupo Controle dispunha apenas de seu computador e conhecimento, simulando o cenário tradicional de aprendizado da disciplina.

4.15. Transparência e Ciência Aberta

Alinhado aos princípios da Ciência Aberta (UNESCO, 2021), que visa promover a transparência, a reprodutibilidade e a colaboração na pesquisa científica, este trabalho disponibiliza publicamente os materiais utilizados para a análise de dados. Foi criado um repositório na plataforma GitHub[2], contendo o conjunto de dados anonimizados dos participantes, garantindo o sigilo das identidades em conformidade com as diretrizes éticas, além dos scripts em linguagem *Python* utilizados para os cálculos estatísticos de *Bootstrap*, SUS e NPS.

[2] https://github.com/Ronec1r/Analise-TCC

5. RESULTADOS E DISCUSSÃO

A apresentação dos resultados está organizada em cinco etapas: (1) Análise global do desempenho e equivalência entre grupos; (2) Análise detalhada por tópico visual; (3) Avaliação da experiência do usuário (Usabilidade e Satisfação); (4) Discussão dos resultados em comparação a literatura; (5) Análise Individual: Triangulação entre Desempenho e Percepção.

5.1. Panorama Geral e Impacto na Aprendizagem

Inicialmente, verificou-se a homogeneidade dos grupos. A análise do Pré-Teste indicou que não houve diferença estatisticamente significativa entre o Grupo Controle (GC) e o Grupo Experimental (GE) antes da intervenção ($p > 0.05$), validando a equivalência inicial de conhecimento. No Pós-Teste, ambos os grupos apresentaram evolução nas notas. A Tabela 2 resume as estatísticas descritivas.

Tabela 2 - Estatísticas Descritivas das Notas Totais

Grupo	Número de participantes	Pré-Teste Média ± DP	Pós-Teste Média ± DP	Evolução Média
Controle (Tradicional)	5	$8{,}00 \pm 2{,}91$	$11{,}20 \pm 2{,}16$	$+3{,}20$
Experimental (*VisuAlgo*)	6	$6{,}83 \pm 1{,}72$	$10{,}00 \pm 1{,}41$	$+3{,}17$

Fonte: Elaborado pelo autor (2026)

Para mitigar o tamanho reduzido da amostra ($n = 11$) e verificar a robustez dos resultados, utilizou-se a técnica de Bootstrap com 10.000 reamostragens. A Figura 5 apresenta as distribuições de densidade de probabilidade. Observa-se que, embora a média do Grupo Experimental seja numericamente inferior, o intervalo de confiança da diferença (gráfico vermelho) cruza a linha zero, indicando estatisticamente que o uso da ferramenta não prejudicou o aprendizado geral em comparação ao método tradicional, mantendo a eficácia pedagógica.

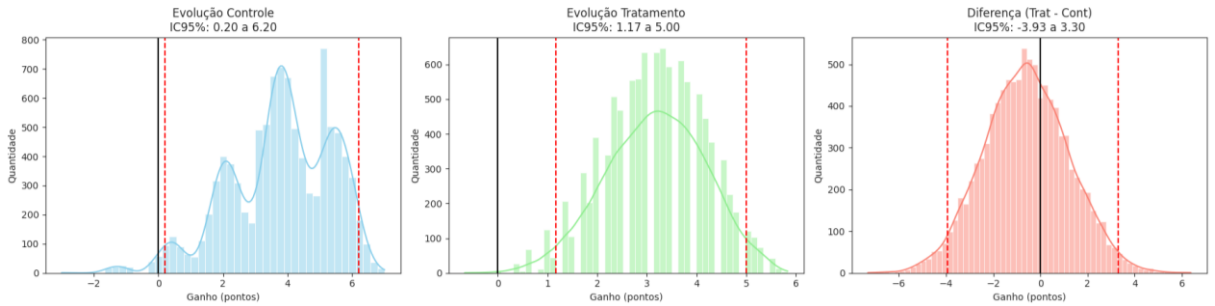


Figura 6 - Distribuição das médias de ganho de aprendizagem (*Bootstrap* com 10.000 iterações)
Fonte: Elaborado pelo autor (2026)

A análise inferencial via *Bootstrap* revelou que, apesar de o Grupo Controle apresentar uma média final numericamente superior (11,20) em comparação ao Grupo Experimental (10,00), a diferença não apresentou significância estatística ($p > 0,05$) dentro do intervalo de confiança de 95%, devido à sobreposição das distribuições e ao tamanho amostral reduzido.

Este resultado sugere uma equivalência pedagógica entre os métodos no que tange ao desempenho global. Um dado crucial é a taxa de evolução: o método tradicional obteve um ganho médio (+3,20) praticamente idêntico ao método mediado por *software* (+3,17). Isso indica que, embora o *VisuAlgo* seja visualmente engajador, ele não gerou, isoladamente, uma alavancagem de notas superior à instrução direta e robusta conduzida pelo docente.

5.2. Análise Estratificada por Tópico

Para compreender as nuances do aprendizado em cada grupo, o pós-teste foi segmentado em três categorias de conhecimento: (1) Terminologia e Conceitos Básicos; (2) Algoritmos de Percurso (Pré, Pós e Em-ordem); e (3) Operações Dinâmicas (Inserção e Remoção).

A análise segmentada por competências é detalhada no gráfico 1 através de um gráfico de tamanho de efeito (*Forest Plot*). A linha vertical central representa a neutralidade. Marcadores à direita indicam tópicos onde o *VisuAlgo* foi superior, favorecendo a visualização. Marcadores à esquerda indicam superioridade da aula expositiva, confirmando que a lógica procedimental exige mediação humana detalhada.

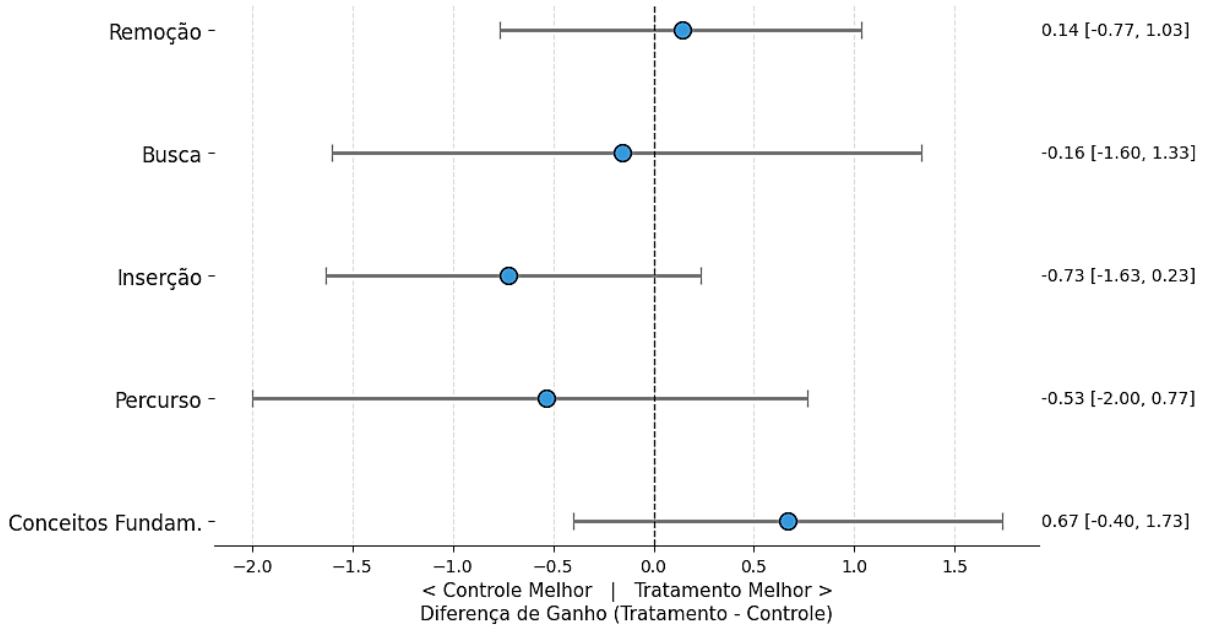


Figura 7 - Gráfico do Impacto do tratamento por habilidade específica (*Forest Plot*). Valores à direita indicam superioridade do *VisuAlgo*; à esquerda, superioridade da aula expositiva

Fonte: Elaborado pelo autor (2026)

A análise segmentada revela uma inversão de eficácia dependendo da natureza do conhecimento:

1. **A Força do Visual (Fundamentos):** Nas questões de identificação estática, o Grupo Experimental superou o Controle (95,8% vs. 85,0%). Isso confirma que a representação gráfica do *VisuAlgo* é extremamente eficiente para criar modelos mentais imediatos sobre a estrutura da árvore. O aluno "vê" o conceito e o assimila com rapidez, validando o princípio da codificação dual.
2. **O Colapso da Recursividade (Percursos):** O dado mais crítico do estudo reside na categoria de percursos. Enquanto o Grupo Controle, instruído via aula expositiva e teste de mesa, manteve um aproveitamento de excelência (86,7%), o Grupo Experimental sofreu uma queda abrupta, acertando apenas 44,4% das questões. Esse resultado indica que a animação fluida do *software* pode ser prejudicial para o ensino de recursão. Ao ver o "ponto de luz" percorrendo a árvore rapidamente, o aluno perde a percepção da pilha de execução (*stack trace*) que ocorre nos bastidores. Ele vê o movimento, mas não entende a regra lógica que determinou aquele movimento, falhando em reproduzi-lo manualmente no papel.
3. **Regras de Negócio (Operações):** Nas operações de manutenção da árvore (Inserção e Remoção), o método tradicional também se mostrou ligeiramente

superior (74,3% contra 69,0%). Embora a diferença seja menor aqui, sugere-se que a explicação docente sobre os casos de borda (ex: remoção de nó com dois filhos) gerou uma compreensão mais sólida das regras de rebalanceamento do que a observação passiva das animações.

5.3. Usabilidade (SUS) e Satisfação (NPS)

A aceitação da tecnologia pelos discentes foi mensurada através de dois instrumentos padronizados: a *System Usability Scale* (SUS), focada na facilidade de uso, e o *Net Promoter Score* (NPS), focado na satisfação e lealdade.

5.4. Análise de Usabilidade (SUS)

O escore médio de usabilidade obtido pelo grupo experimental foi de 73,8 pontos. De acordo com a escala de classificação de Bangor, Kortum e Miller (2009), este valor situa o *VisuAlgo* na categoria "Bom" (*Good*), superando a média global de referência para sistemas de *software*, que é de 68 pontos. A Figura 8 apresenta a distribuição dos scores.

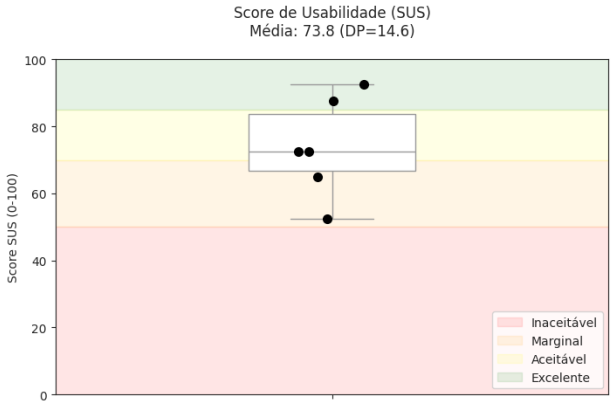


Figura 8 - Gráfico da Avaliação de Usabilidade (*System Usability Scale*)

Fonte: Elaborado pelo autor (2026)

A análise detalhada aponta para dois extremos de interação:

- Alta Eficiência e Entusiasmo (Alunos A09 e A11) Os alunos A09 e A11 atribuíram notas de usabilidade na faixa de "Excelência" (92,5 e 87,5 pontos, respectivamente). Esta percepção de uma *interface* transparente correlacionou-se diretamente com o

desempenho acadêmico, visto que ambos obtiveram notas altas (10,0 e 11,0). Para estes usuários, a barreira tecnológica foi inexistente.

- Consistência Pragmática (Alunos A06 e A10) Um achado crucial reside no perfil dos alunos A06 e A10, que avaliaram o sistema com o mesmo score de 72,5 pontos (classificação "Bom"). O destaque é o aluno A10, que, mesmo sem considerar a interface "perfeita", obteve a maior nota absoluta da turma (12,0). O aluno A06 também obteve nota sólida (10,0). Isso sugere que não é necessário que o *software* seja percebido como "Excelente" para ser eficaz; uma usabilidade "Boa" já é suficiente para remover as barreiras cognitivas e permitir que o aluno de alta performance (como o A10) atinja seu potencial máximo.
- Zona de Fricção e Alerta (Alunos A07 e A08) Na parte inferior do espectro, a usabilidade impactou negativamente. O aluno A07, com SUS de 65,0 (abaixo da média de mercado de 68), situou-se na zona "Marginal", obtendo um desempenho mediano (Nota 9,0). O caso mais crítico, contudo, é o do aluno A08, que avaliou o sistema com 52,5 pontos ("Ruim"). A alta carga cognitiva imposta pela dificuldade de uso refletiu-se diretamente em seu resultado: ele obteve a pior nota do grupo (8,0).

Essa estratificação confirma que a usabilidade atua como um "filtro": quando ela é Boa ou Excelente (A06, A10, A09, A11), o aprendizado flui; quando ela cai para níveis Marginais (A07) ou Ruins (A08), o desempenho acadêmico é prejudicado.

5.5. Índice de Lealdade (NPS)

Quanto à probabilidade de recomendação da ferramenta, o cálculo do NPS resultou em um índice de +50. Na metodologia de Reichheld (2003), este valor classifica a ferramenta na "Zona de Qualidade". A Figura 9 detalha a segmentação dos perfis.

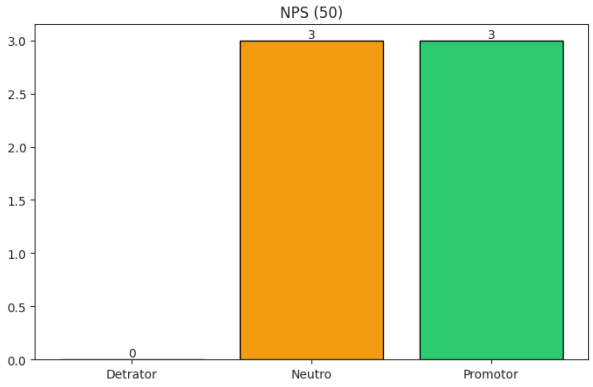


Figura 9 - Gráfico da Classificação *Net Promoter Score* (NPS)

Fonte: Elaborado pelo autor (2026)

Observou-se um cenário polarizado positivamente:

- 50% Promotores: Alunos que atribuíram notas 9 ou 10, indicando entusiasmo com a metodologia visual.
- 50% Neutros (Passivos): Alunos que atribuíram notas 7 ou 8, indicando que usaram a ferramenta sem problemas, mas não se sentiram engajados emocionalmente.
- 0% Detratores: Não houve notas abaixo de 7.

A ausência de detratores é um indicador crítico de sucesso para a implementação pedagógica. Mesmo o aluno que teve dificuldades de usabilidade (A08) atribuiu nota 7 (Neutro) no NPS, sugerindo que ele reconhece o valor da ferramenta para outros colegas, apesar de sua experiência pessoal difícil. Isso confirma que o *VisuAlgo* é percebido como um recurso válido e recomendável para o apoio ao ensino de Estruturas de Dados.

5.6. Discussão e comparação com a literatura

Os resultados obtidos neste estudo desenham um cenário de "dualidade pedagógica" que dialoga intensamente com o estado da arte mapeado no Capítulo 3. A disparidade de desempenho observada — onde o Grupo Experimental dominou a identificação visual, mas falhou na lógica recursiva — oferece evidências empíricas que refinam as conclusões de trabalhos anteriores.

5.7. A Construção do Modelo Mental e a Codificação Dual

A superioridade do Grupo Experimental nas questões de Fundamentos (95,8%) confirma a premissa levantada por Souza et al. (2022) e Freitas et al. (2014) na fundamentação teórica: a principal barreira no ensino de árvores é a abstração. O uso do *VisuAlgo* mitigou essa barreira, permitindo que os alunos visualizassem concretamente conceitos que antes eram apenas teóricos. Este resultado alinha-se aos achados de Nathasya et al. (2019), que observaram melhoria nas notas de alunos que utilizaram a ferramenta DS-PITON. Assim como naquele estudo, a visualização aqui serviu como um catalisador para a compreensão inicial da estrutura, validando a Teoria da Codificação Dual (PAIVIO, 1986).

5.8. A "Ilusão de Competência" e a Dependência da Ferramenta

O ponto crítico deste estudo — a falha do Grupo Experimental na lógica recursiva (44,4%) — ecoa os problemas identificados por Balbino de Paula et al. (2023) com o uso do ChatGPT. Naquele estudo, os autores notaram que, embora a tecnologia aumentasse o engajamento, ela gerava uma dependência onde os alunos não conseguiam implementar códigos do zero. De forma análoga, os alunos que usaram o *VisuAlgo* desenvolveram uma dependência da animação visual. A fluidez do *software* mascarou a complexidade da pilha de execução (*stack trace*), levando a um entendimento superficial. Isso reforça a necessidade de metodologias de Aprendizagem Ativa, como os jogos propostos por Rojas-Salazar et al. (2020) (DS-Hacker) e Dicheva e Hodge (2018) (*The Stack Game*). A mera observação passiva (como feita neste experimento) mostrou-se insuficiente comparada às abordagens gamificadas ou à mediação ativa do professor (Vygotsky) observada no Grupo Controle.

5.9. Usabilidade como Fator de Exclusão

A correlação entre baixa usabilidade e notas inferiores valida a Teoria da Carga Cognitiva. O caso do aluno A08 é emblemático: ao avaliar o sistema com um SUS de 52,5 (Ruim/Marginal), ele obteve a pior nota do grupo (8,0). Isso confirma os alertas de design instrucional de Ravenscroft (2018): quando a interface impõe uma carga cognitiva estranha (dificuldade de uso), ela rouba recursos mentais que deveriam ser

alocados para o aprendizado do conteúdo (carga intrínseca). Em contraste, os alunos A09 e A11, que não sentiram essa fricção (SUS > 87), conseguiram focar no conteúdo e obtiveram notas altas. Portanto, a usabilidade não é apenas um detalhe técnico, mas um pré-requisito pedagógico.

5.10. Análise Individual: Triangulação entre Desempenho e Percepção

Dada a natureza reduzida da amostra experimental (n=6), optou-se por realizar uma análise censitária, cruzando os três eixos avaliados: desempenho cognitivo (Pós-Teste), percepção de usabilidade (SUS) e categorias de erro.

Ao contrário de fenômenos de "ilusão de competência" (efeito Dunning-Kruger) frequentemente relatados em ambientes de aprendizagem multimídia, os dados deste estudo revelaram um alinhamento metacognitivo consistente. Não houve casos de alunos que "acharam que aprenderam" sem ter aprendido. Pelo contrário, observou-se uma correlação direta: a dificuldade de uso da ferramenta refletiu-se proporcionalmente na dificuldade de assimilação do conteúdo.

Para ir além da análise subjetiva e identificar padrões de comportamento ocultos nos dados, aplicou-se o algoritmo de agrupamento não-supervisionado K-Means, proposto originalmente por MacQueen (1967). O objetivo foi segmentar os alunos com base na relação entre seu 'Conhecimento Prévio' e o 'Ganho de Aprendizagem' obtido. A Figura 6 apresenta os três perfis (*clusters*) identificados estatisticamente, permitindo visualizar quem foram os alunos que tiveram aquisição acelerada *versus* aqueles que estagnaram.

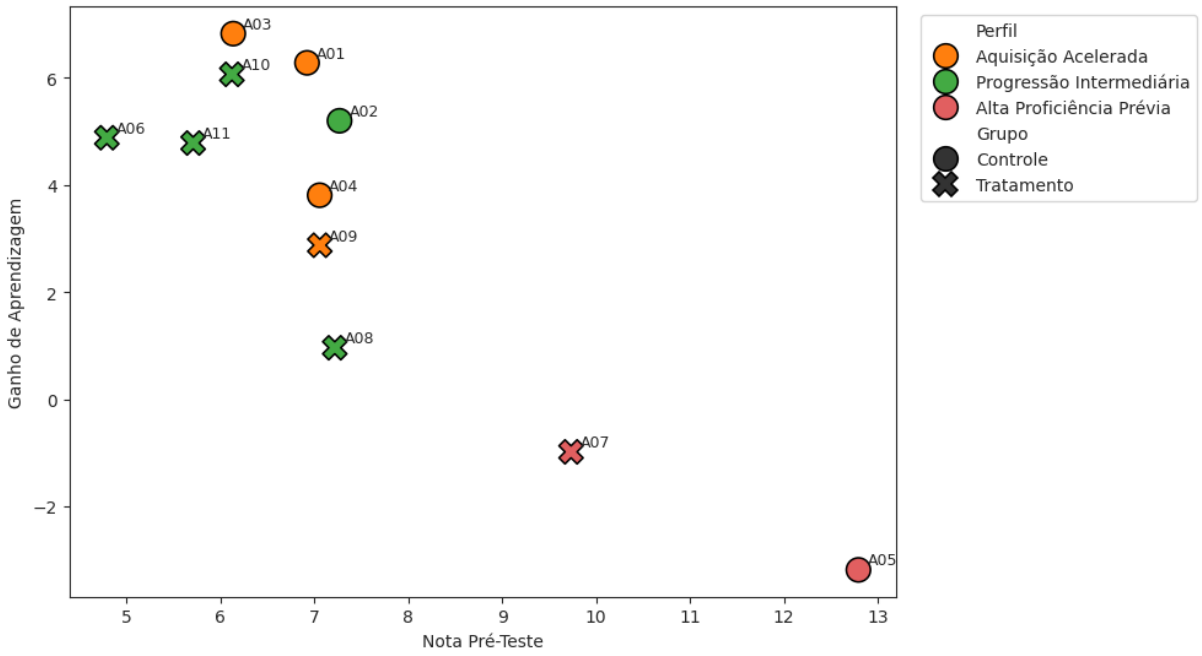


Figura 10 - Gráfico de agrupamento dos perfis de aprendizagem relacionando conhecimento prévio e ganho pós-intervenção

Fonte: Elaborado pelo autor (2026)

A Tabela 3 apresenta a triangulação dos dados individuais.

Tabela 3 - Perfil Individual dos Estudantes (Grupo Experimental)

ID do Aluno	Nota Pós-Teste (0-14)	Score SUS (0-100)	Classificação SUS	Perfil Identificado	Principais Dificuldades (Erros)
A06	10	72,5	Bom	Consistente	Fundamentos e remoção complexa
A07	9	65	OK (Marginal)	Mediano	Percursos e Antecessor/Sucessor
A08	8	52,5	Ruim	Fricção	Algoritmos de Percurso (Recursão)
A09	10	72,5	Bom	Eficiente	Percursos e Antecessor/Sucessor
A10	12	92,5	Excelente	Entusiasta	Percursos e Antecessor/Sucessor
A11	11	87,5	Excelente	Otimizado (Alto Desempenho)	Algoritmos de Percurso (Recursão)

Fonte: Elaborado pelo autor (2026)

A análise destes perfis permite identificar três cenários distintos de interação Humano-Computador no contexto educacional:

1. **A Eficiência Pragmática (Aluno A10):** O aluno A10 representa o caso de sucesso pedagógico ideal, obtendo a maior nota da turma (12,0). Curiosamente, ele não

avaliou o *software* como perfeito, atribuindo um SUS de 72,5 ("Bom", mas não "Excelente"). Isso indica que, para alunos com alto raciocínio lógico, a ferramenta não precisa ser impecável; desde que a usabilidade seja funcional (acima do corte de 68), eles conseguem superar pequenas barreiras de interface e extrair o máximo do conteúdo. O A10 foi o único a errar exclusivamente questões de recursão, dominando todo o restante.

2. **O Cenário Otimizado (Alunos A11 e A9):** Os alunos A11 e A9 tiveram a melhor experiência de uso, com scores SUS de 87,5 e 92,5 (nível de "Excelência").
    - O Aluno A11 converteu essa facilidade de uso em alto desempenho (Nota 11,0), sugerindo um alinhamento perfeito entre ferramenta e usuário.
    - O Aluno A9, embora tenha dado a maior nota de usabilidade da sala (92,5), obteve nota 10,0 (igual ao A06). Isso traz um *insight* valioso: "amar" a ferramenta facilita o estudo, mas não garante a compreensão das regras lógicas complexas (ele também errou a recursão).
3. **A Zona de Resiliência e Alerta (Alunos A06 e A07):** Aqui observamos o impacto gradual da usabilidade.
    - O **Aluno A06** avaliou o sistema com 72,5 (igual ao A09) e obteve nota 10,0. Ele demonstra um perfil "Resiliente": conseguiu aprender bem os fundamentos e operações, ignorando eventuais dificuldades da interface.
    - Já o Aluno A07 acende um sinal de alerta. Com um SUS de 65,0 (classificado como "Marginal" e abaixo da média de mercado), sua nota caiu para 9,0. Diferente do A06, a fricção com a interface começou a afetar seu rendimento, levando-o a errar não só a recursão, mas também conceitos de sucessor/antecessor.
4. **O Colapso por Carga Cognitiva (Aluno A08):** O caso do aluno A08 é a evidência estatística mais forte do estudo. Sendo o único a classificar o sistema como "Ruim" (SUS 52,5), ele obteve a pior nota do grupo (8,0). A análise de seus erros mostra falhas generalizadas (Recursão, Inserção e Remoção). Isso valida a Teoria da Carga Cognitiva: o esforço mental excessivo para operar o *VisuAlgo* (carga estranha) consumiu os recursos que deveriam ser usados para aprender a matéria (carga intrínseca), resultando em baixo aprendizado.

6. CONCLUSÃO

O presente estudo investigou o impacto da ferramenta de visualização *VisuAlgo* no processo de ensino-aprendizagem de Árvores Binárias de Busca, confrontando a eficácia de metodologias baseadas em *software versus* a instrução expositiva tradicional. A pesquisa, conduzida sob um delineamento quase-experimental triangulado com métricas de usabilidade e satisfação, permitiu responder à questão central do trabalho, revelando que a tecnologia não atua como um substituto universal, mas como um recurso de eficácia condicionada à natureza do conteúdo cognitivo.

6.1. Síntese dos Achados e Diálogo com a Literatura

Os dados refutam a hipótese simplista de superioridade global da tecnologia. Observou-se uma dicotomia clara no desempenho discente:

- **No domínio visual-estrutural**, o Grupo Experimental demonstrou superioridade estatística (95,8% de acerto em Fundamentos). Este resultado corrobora a Teoria da Codificação Dual (PAIVIO, 1986) e alinha-se aos achados de Nathasya et al. (2019), confirmando que a representação gráfica dinâmica facilita a construção de modelos mentais concretos, superando as barreiras de abstração citadas por Souza et al. (2022).
- **No domínio lógico-procedural**, contudo, a metodologia tradicional mostrou-se significativamente mais eficaz. A falha do Grupo Experimental em questões de recursividade (44,4% de acerto) ecoa os alertas de Hundhausen et al. (2002) sobre a "visualização passiva". A fluidez da animação no *software* mascarou a complexidade da pilha de execução (*stack trace*), gerando uma compreensão superficial. Isso valida a perspectiva socio interaccionista de Vygotsky (1991), demonstrando que, para processos lógicos invisíveis, a mediação humana (o professor detalhando o teste de mesa) atua como um scaffolding insubstituível.

Adicionalmente, a correlação positiva entre usabilidade (SUS) e desempenho acadêmico confirmou a Teoria da Carga Cognitiva (SWELLER, 2011). Falhas na *interface* geraram Carga Cognitiva Estranha, prejudicando a aprendizagem, o que dialoga com as preocupações de design instrucional levantadas por Ravenscroft (2018).

6.2. Validação da Usabilidade e Carga Cognitiva

A avaliação de usabilidade (SUS médio de 73,75) e satisfação (NPS +50) classificou o VisuAlgo como uma ferramenta "Boa" e situou-a na "Zona de Qualidade". Contudo, a análise individual confirmou a Teoria da Carga Cognitiva:

- O caso do aluno **A08** (Nota 8,0 e SUS 52,5) evidenciou que a "fricção" com a interface atua como **Carga Cognitiva Estranha**. A dificuldade em operar o sistema competiu com o processamento do conteúdo, resultando no pior desempenho da turma.
- Em contrapartida, os alunos que não enfrentaram barreiras de interface (como A09 e A11) conseguiram direcionar seus recursos cognitivos para o aprendizado, obtendo notas de excelência. Isso valida que a usabilidade não é apenas um requisito técnico, mas pedagógico.

6.3. Implicações para a Prática Docente

Diante da evidência de que o *software* é excelente para "mostrar" mas insuficiente para "explicar a lógica profunda", recomenda-se a adoção de uma Abordagem Híbrida Sequencial:

1. **Fase Introdutória (Visual):** Uso do *VisuAlgo* para apresentação dos conceitos e regras estruturais, aproveitando seu alto engajamento e clareza visual.
2. **Fase de Aprofundamento (Tradicional):** Intervenção docente com testes de mesa manuais e exploração detalhada da recursão no quadro, suprindo a lacuna deixada pela visualização automática.
3. **Fase de Consolidação (Prática):** Retorno ao *software* para validação de exercícios e simulação de casos de borda.

6.4. Limitações do Estudo

A interpretação destes resultados deve considerar as restrições metodológicas inerentes à pesquisa. A principal limitação reside no tamanho da amostra (n=11), um desafio recorrente na área de Informática na Educação, também reportado por Teresco (2018) em estudos similares. Embora a análise censitária e o uso de *Bootstrap* tenham mitigado o impacto estatístico, a generalização dos achados

(validade externa) é limitada. Ademais, o recorte transversal do estudo (intervenção pontual) não permitiu avaliar a retenção do conhecimento a longo prazo ou a curva de aprendizado da interface mencionada por Balbino de Paula et al. (2023).

6.5. Trabalhos Futuros

Para pesquisas subsequentes, sugere-se:

- A replicação deste protocolo com amostras ampliadas e em delineamento longitudinal.
- A investigação de estratégias de Engajamento Ativo (*Active Learning*), como a técnica *Stop-and-Think* (parar e pensar), onde o estudante deve prever o comportamento do algoritmo antes da animação do software, visando romper a passividade cognitiva observada neste estudo.
- A análise comparativa com outras ferramentas de visualização que possuam recursos explícitos de visualização de código e memória (*call stack*), para verificar se a limitação na aprendizagem de recursão persiste.

Em suma, conclui-se que o *VisuAlgo* é uma ferramenta pedagógica potente, desde que utilizada não como protagonista autônoma, mas como instrumento auxiliar sob a regência de uma mediação docente intencional e estruturada.

7. REFERÊNCIAS

- BALBINO DE PAULA, Taw-Ham Almeida et al. **Aprendizagem de estrutura de dados utilizando o ChatGPT como ferramenta auxiliar: um relato de experiência com o conteúdo de árvores binárias.** In: SIMPÓSIO BRASILEIRO DE INFORMÁTICA NA EDUCAÇÃO (SBIE), 34., 2023. Anais [...]. Niterói: SBC, 2023. Disponível em https://sol.sbc.org.br/index.php/wei/article/view/29643. Acesso em: 18 ago. 2025.

- BANGOR, Aaron; KORTUM, Philip T.; MILLER, James T. **An empirical evaluation of the system usability scale.** International Journal of Human-Computer Interaction, v. 24, n. 6, p. 574-594, 2008.

- BATTISTELLA, Paulo Eduardo; WANGENHEIM, Aldo von; WANGENHEIM, Christiane Gresse von. **SORTIA: um jogo para ensino de algoritmos de ordenação.** In: SIMPÓSIO BRASILEIRO DE INFORMÁTICA NA EDUCAÇÃO (SBIE), 23., 2012, Rio de Janeiro. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2012. p. 1–10.

- COHEN, Jacob. **Statistical power analysis for the behavioral sciences.** 2. ed. Hillsdale: Lawrence Erlbaum Associates, 1988.

- CORMEN, Thomas H. et al. **Algoritmos: teoria e prática. Tradução de Arlete Simille Marques. 3. ed.** Rio de Janeiro: Elsevier, 2012. Disponível em https://computerscience360.wordpress.com/wp-content/uploads/2018/02/algoritmos-teoria-e-prc3a1tica-3ed-thomas-cormen.pdf. Acesso em: 18 ago. 2025.

- CRITICAL APPRAISAL SKILLS PROGRAMME. **Checklist para Estudos Qualitativos.** Oxford: CASP, 2024. Disponível em: https://casp-uk.net/casp-tools-checklists/. Acesso em: 17 ago. 2025.

- DICHEVA, Darina; HODGE, Austin. **Active Learning through Game Play in a Data Structures Course.** In: ACM TECHNICAL SYMPOSIUM ON COMPUTER SCIENCE EDUCATION (SIGCSE), 49., 2018, Baltimore. Proceedings [...]. New York: ACM, 2018. p. 481-486. https://doi.org/10.1145/3159450.3159605.

- DUARTE, D. D. **Análise das ementas de estruturas de dados das universidades brasileiras.** [S. l.], 2021. https://doi.org/10.5753/WEI.2015.10260.

- FREITAS, Mateus Felipe; MOTA, Sâmela Daiere Soares; SOARES, Liziane Santos; REIS, Rachel Carlos Duque. **PORTEC: uma ferramenta para auxiliar na abstração dos conceitos de estrutura de dados.** In: CONGRESSO BRASILEIRO DE INFORMÁTICA NA EDUCAÇÃO (CBIE), 3., 2014, Dourados. Anais [...]. Porto Alegre: SBC, 2014. p. 872–881.

- GOODRICH, Michael T.; TAMASSIA, Roberto; GOLDWASSER, Michael H. **Estruturas de Dados e Algoritmos em Java.** 6. ed. Porto Alegre: Bookman, 2014.

- HALIM, S.; HALIM, F. **Competitive Programming 3: The New Lower Bound of Programming Contests.** 3. ed. Singapura: Lulu Press, 2013.

- HARA, Murilo Mickio Soares; SISCOUTTO, Robson Augusto. **Objetos de aprendizagem para ensino de estruturas de dados fazendo uso de realidade aumentada: SEDRA.** Colloquium Exactarum, Presidente Prudente, v. 10, n. 1, p. 62–77, jan./mar. 2018.

- HAUKOOS, Jason S.; LEWIS, Roger J. **Advanced statistics: bootstrapping confidence intervals for statistics with “difficult” distributions.** Academic Emergency Medicine, v. 12, n. 4, p. 360-365, 2005.

- HIGGINS, Julian P. T.; THOMAS, J. (ed.). **Cochrane Handbook for Systematic Reviews of Interventions.** 2. ed. West Sussex: John Wiley & Sons, 2019.

- HUNDHAUSEN, C. D.; DOUGLAS, S. A.; STASKO, J. T. **A meta-study of algorithm visualization effectiveness.** Journal of Visual Languages & Computing, v. 13, n. 3, p. 259-290, 2002.

- JAGADEESHA, Ashwin et al. **Integrating data structures and algorithms in K-12 education using block-based programming**. arXiv, 2023. Preprint. Disponível em: https://arxiv.org/abs/2302.11659. Acesso em: 11 jun. 2025.

- KITCHENHAM, Barbara; CHARTERS, Stuart. **Guidelines for performing Systematic Literature Reviews in Software Engineering.** Keele, UK: Keele

University, 2007. (Technical Report EBSE-2007-01). Disponível em: https://www.researchgate.net/profile/Barbara-Kitchenham/publication/302924724_Guidelines_for_performing_Systematic_Literature_Reviews_in_Software_Engineering/links/61712932766c4a211c03a6f7/Guidelines-for-performing-Systematic-Literature-Reviews-in-Software-Engineering.pdf. Acesso em: 18 ago. 2025.

- KNUTH, Donald E. **The art of computer programming. 3. ed. v. 1: Fundamental algorithms.** Reading: Addison-Wesley, 1997. Disponível em: https://seriouscomputerist.atariverse.com/media/pdf/book/Art%20of%20Computer%20Programming%20-%20Volume%201%20(Fundamental%20Algorithms).pdf. Acesso em: 18 ago. 2025.

- KOLB, David A. **Experiential learning: experience as the source of learning and development.** Englewood Cliffs: Prentice-Hall, 1984.

- KRUGER, Justin; DUNNING, David. **Unskilled and unaware of it: how difficulties in recognizing one's own incompetence lead to inflated self-assessments.** Journal of Personality and Social Psychology, v. 77, n. 6, p. 1121-1134, 1999.

- KUMAR, Amruth N. et al. **Computer Science Curricula 2023. New York: ACM Press; IEEE Computer Society Press; AAAI Press, 2024.** Disponível em: https://doi.org/10.1145/3664191. Acesso em: 27 maio 2025.

- LAHTINEN, Essi; ALA-MUTKA, Kirsti; JÄRVINEN, Hannu-Matti. **A study of the difficulties of novice programmers.** In: PROCEEDINGS of the 10th annual SIGCSE conference on Innovation and technology in computer science education. Caparica, Portugal: ACM, 2005. p. 14-18.

- LOURENCO, Douglas Fabiano; CARMONA, Elenice Valentim; LOPES, Maria Helena Baena de Moraes. **Translation and Cross-Cultural Adaptation of the System Usability Scale to Brazilian Portuguese.** Aquichan, Bogotá, v. 22, n. 2, 2022. DOI: 10.5294/aqui.2022.22.2.8.

- MACQUEEN, J. **Some methods for classification and analysis of multivariate observations.** In: PROCEEDINGS OF THE FIFTH BERKELEY SYMPOSIUM ON

MATHEMATICAL STATISTICS AND PROBABILITY, 1., 1967, Berkeley. Proceedings... Berkeley: University of California Press, 1967. p. 281-297.

- MCQUAIGUE, Matthew et al. **Visualization, Assessment and Analytics in Data Structures Learning Modules.** In: ACM TECHNICAL SYMPOSIUM ON COMPUTER SCIENCE EDUCATION, 49., 2018, Baltimore. Anais [...]. New York: ACM, 2018. p. 864-869. Disponível em: https://dl.acm.org/doi/10.1145/3159450.3159460. Acesso em: 6 dez. 2025.

- MOHER, David et al. **Preferred Reporting Items for Systematic Reviews and Meta-Analyses: The PRISMA Statement.** PLoS Medicine, v. 6, n. 7, e1000097, 2009.

- NATHASYA, Rossevine Artha et al. **Integrating program and algorithm visualisation for learning data structure implementation.** Egyptian Informatics Journal, v. 20, n. 3, p. 193-204, 2019. https://doi.org/10.1016/j.eij.2019.05.001.

- OLIVEIRA, Luiz Ricardo do Carmo de; SOUZA, Ian Simon Pinheiro de; FRONER, Diego da Silva; SOUZA FILHO, Aneil Martins de. **Desenvolvimento de um aplicativo móvel educacional voltado ao ensino de estrutura de dados.** In: SIMPÓSIO BRASILEIRO DE INFORMÁTICA NA EDUCAÇÃO (SBIE), 27., 2016, São Paulo. Anais [...]. Porto Alegre: SBC, 2016. p. 559–568.

- PAIVIO, A. **Mental representations: A dual coding approach.** Oxford: Oxford University Press, 1986.

- PATTA, Marilée; MACEDO, Reginaldo Morais de. **Estudo da reprovação no curso de Sistemas de Informação da Unimontes no período de 2014-1 a 2019-2.** Anais do II Congresso Brasileiro Interdisciplinar em Ciência e Tecnologia (CoBICET), 2021. Evento online, 30 ago. – 03 set. 2021.

- RAVENSCROFT, Robert A. Jr. **Dynamic data structures, a web based tool for teaching linked lists and binary trees.** Journal of Computing Sciences in Colleges, v. 33, n. 6, p. 97-106, 2018. Disponível em: https://dl.acm.org/doi/10.5555/3344051.3344071. Acesso em: 6 dez. 2025

- REICHHELD, Frederick F. **The one number you need to grow.** Harvard Business Review, v. 81, n. 12, p. 46-54, 2003.

- REICHHELD, Frederick F. **The ultimate question: driving good profits and true growth.** Boston, MA: Harvard Business School Press, 2006.

- ROJAS-SALAZAR, Alberto; RAMÍREZ-ALFARO, Paula; HAÁHR, Mads. **Learning Binary Search Trees Through Serious Games.** In: INTERNATIONAL COMPUTER PROGRAMMING EDUCATION CONFERENCE (ICPEC), 1., 2020. Anais […]. Dagstuhl: Leibniz-Zentrum für Informatik, 2020. p. 22:1-22:7. https://doi.org/10.4230/OASIcs.ICPEC.2020.22.

- SOUZA, Bianca; VERAS, Nécio; OLIVINDO, Mayara; MENDES, Elanne; ROCHA, Lincoln; VIANA, Windson. **Ensino invertido de estrutura de dados no contexto do ensino remoto emergencial.** In: SIMPÓSIO BRASILEIRO DE EDUCAÇÃO EM COMPUTAÇÃO (EDUCOMP), 2., 2022, Feira de Santana, BA (on-line). Anais [...]. Porto Alegre: SBC, 2022. p. 77–87.

- SWELLER, J. **Cognitive load during problem solving: Effects on learning.** Cognitive Science, v. 12, n. 2, p. 257-285, 1988.

- SWELLER, J.; AYRES, P.; KALYUGA, S. **Cognitive Load Theory.** New York: Springer, 2011.

- TERESCO, James D. **Graph traversals and spanning trees using metal highway data and visualizations.** In: CCSC ROCKY MOUNTAIN CONFERENCE, 2018, Loudonville. Journal of Computing Sciences in Colleges. v. 34, n. 2, p. 143. Disponível em: https://dl.acm.org/doi/abs/10.5555/3282588.3282603. Acesso em: 6 dez. 2025

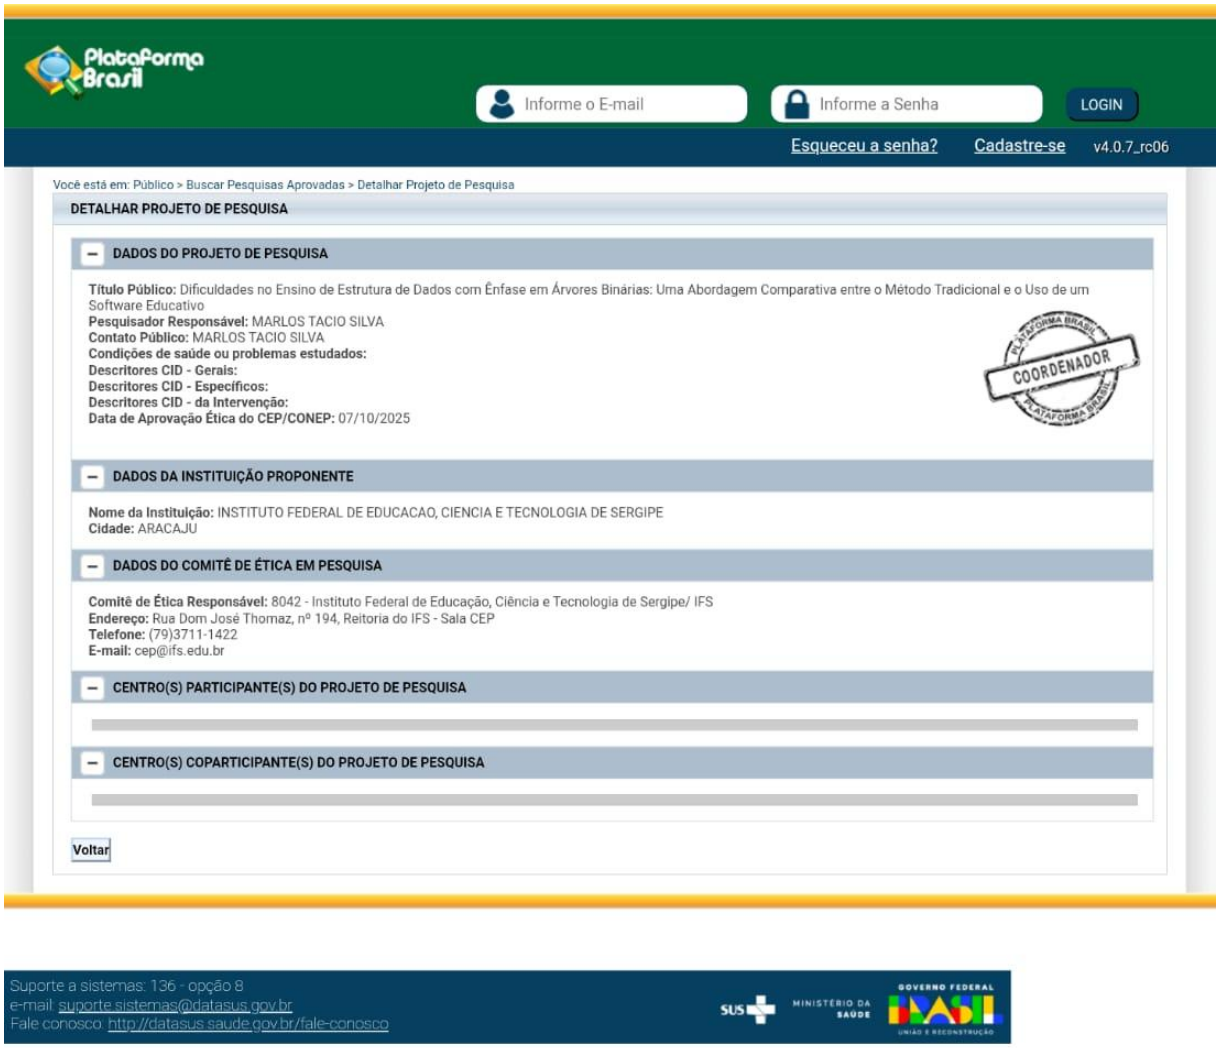
- UNESCO. **Recomendação da UNESCO sobre Ciência Aberta.** Paris: UNESCO, 2021. Disponível em: https://unesdoc.unesco.org/ark:/48223/pf0000379949_por. Acesso em: 20 dez. 2025.

- VYGOTSKY, L. S. **A formação social da mente.** 4. ed. São Paulo: Martins Fontes, 1991.

- WIRTH, Niklaus. **Algorithms + Data Structures = Programs.** Englewood Cliffs: Prentice-Hall, 1976. Disponível em [link]. Acesso em: 18 ago. 2025.

8. APÊNDICES

8.1. Aprovação do Comitê de ética do Instituto Federal de Sergipe (IFS)



8.2. Questionário de Desempenho

QUESTIONÁRIO DE DESEMPENHO

Agradecemos imensamente sua colaboração nesta pesquisa. Nosso objetivo com este instrumento é avaliar o nível de entendimento conceitual sobre o tema "Árvores Binárias de Busca" em Estrutura de Dados. As questões a seguir foram elaboradas para avaliar esse nível nos principais tópicos, desde a terminologia básica até as operações de manipulação da estrutura. Pedimos que você responda da melhor forma possível, pois seu desempenho nos ajudará a traçar um panorama preciso sobre o aprendizado do assunto. Ressaltamos que sua participação é voluntária e todas as suas respostas são anônimas e confidenciais, e também não afeta sua nota na disciplina. Os dados coletados serão analisados em conjunto e serão fundamentais para identificar os principais desafios no ensino de árvores binárias, visando aprimorar as estratégias pedagógicas para futuras turmas. O tempo para resposta do questionário é de 1 hora corrida, podendo pausar a qualquer momento sem nenhuma restrição, e caso seja seu desejo, pode interromper a resposta do questionário.

INFORMAÇÕES GERAIS

Idade:

Período que está cursando:

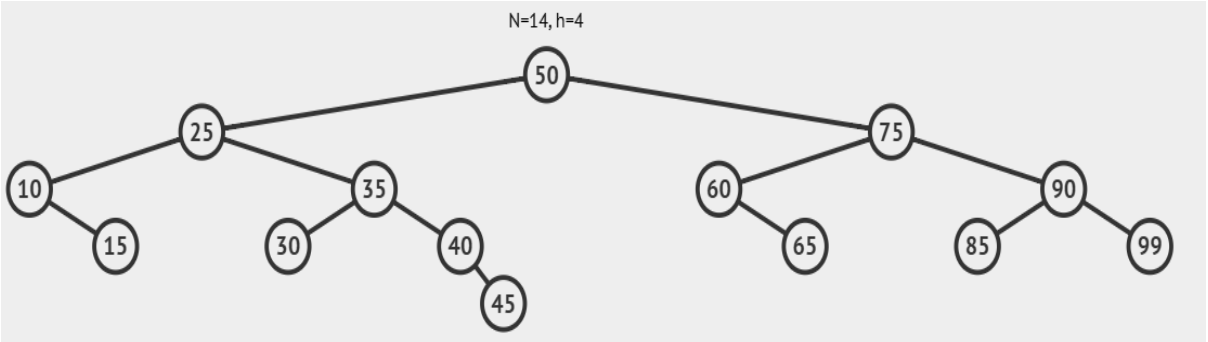
Gênero: ( ) feminino ( ) masculino ( ) outros

Experiência prévia com programação: ( ) Avançada ( ) Intermediária ( ) Básica ( ) Nenhuma

Em uma escala de 1 a 4, quão confiante você se sente sobre o entendimento de árvores binárias?

1 ( ) Totalmente Inseguro
2 ( ) Inseguro
3 ( ) Confiante
4 ( ) Totalmente Confiante

SEÇÃO A: TERMINOLOGIA E CONCEITOS FUNDAMENTAIS



Instruções: Para cada questão, leia o enunciado e as opções cuidadosamente. Todas as questões se referem à Árvore de Principal apresentada no início desta seção.

1. Qual nó é a raiz da Árvore Principal?

a) 10

b) 100

c) 50

d) 75

e) 25

2. Qual das seguintes opções lista todos os nós folhas na Árvore Principal?

a) 15, 30, 45, 65, 85, 99

b) 10, 35, 40, 60, 90

c) 50, 25, 75

d) 15, 30, 45, 60, 85, 99

e) 15, 30, 40, 45, 65, 85, 99

3. Na Árvore Principal, qual é o nó pai do nó 40?

a) 25

b) 30

c) 45

d) 35

e) 50

4. Quais são os filhos do nó 75?

a) 50 e 90

b) 60 e 90

c) 60 e 85

d) 65 e 100

e) Apenas o nó 60

SEÇÃO B: PERCURSOS EM ÁRVORES

5. Qual é a sequência de nós visitados ao realizar um percurso em PRÉ-ORDEM na Árvore Principal ?

a) 50, 25, 10, 15, 35, 30, 40, 45, 75, 60, 65, 90, 85, 99
b) 15, 10, 30, 45, 40, 35, 25, 65, 60, 85, 99, 90, 75, 50
c) 10, 15, 25, 30, 35, 40, 45, 50, 60, 65, 75, 85, 90, 99
d) 50, 25, 75, 10, 35, 60, 90, 15, 30, 40, 65, 85, 99, 45
e) 50, 75, 90, 99, 85, 60, 65, 25, 35, 40, 45, 30, 10, 15

6. Qual é a sequência de nós visitados ao realizar um percurso em EM-ORDEM na Árvore Principal?

a) 50, 25, 10, 15, 35, 30, 40, 45, 75, 60, 65, 90, 85, 99
b) 99, 90, 85, 75, 65, 60, 50, 45, 40, 35, 30, 25, 15, 10
c) 10, 15, 25, 30, 35, 40, 45, 50, 60, 65, 75, 85, 90, 99
d) 50, 25, 75, 10, 35, 60, 90, 15, 30, 40, 65, 85, 99, 45
e) 15, 10, 30, 45, 40, 35, 25, 65, 60, 85, 99, 90, 75, 50

7. Qual é a sequência de nós visitados ao realizar um percurso em PÓS-ORDEM na Árvore Principal?

a) 50, 25, 10, 15, 35, 30, 40, 45, 75, 60, 65, 90, 85, 99
b) 15, 10, 30, 45, 40, 35, 25, 65, 60, 85, 99, 90, 75, 50
c) 10, 15, 25, 30, 35, 40, 45, 50, 60, 65, 75, 85, 90, 99
d) 15, 30, 45, 40, 35, 10, 25, 65, 60, 85, 99, 90, 75, 50
e) 99, 85, 90, 65, 60, 75, 45, 40, 30, 35, 15, 10, 25, 50

SEÇÃO C: ÁRVORES BINÁRIAS DE BUSCA (BST)

8. Se os valores 42 e 88 fossem inseridos, nesta ordem, na Árvore Principal, quais seriam suas posições finais?

a) O nó 42 se tornaria o filho direito do nó 40, e o nó 88 se tornaria o filho esquerdo do nó 90.

b) O nó 42 se tornaria o filho esquerdo do nó 45, e o nó 88 se tornaria o filho direito do nó 85.

c) O nó 42 se tornaria o filho esquerdo do nó 40, e o nó 88 se tornaria o filho direito do nó 90.

d) O nó 42 se tornaria o filho esquerdo do nó 45, e o nó 88 se tornaria o filho esquerdo do nó 99.

e) O nó 42 se tornaria o filho esquerdo do nó 45, e o nó 88 se tornaria o filho esquerdo do nó 90.

9. Qual é o caminho percorrido na Árvore Principal para encontrar o nó com o valor 45?

a) 50, 25, 10, 15, 45

b) 50, 75, 60, 65, 45

c) 50, 25, 35, 40, 45

d) 50, 25, 35, 30, 45

e) 50, 25, 40, 45

10. Qual é o nó SUCESSOR do nó 50 (a raiz)?

a) 75

b) 25

c) 65

d) 45

e) 60

11. Qual é o nó ANTECESSOR do nó 50 (a raiz)?

a) 25

b) 35

c) 40

d) 45

e) 15

12. Se o nó 15 fosse removido da Árvore Principal, qual afirmação descreveria a mudança na estrutura?

a) O nó 10 também será removido em cascata.

b) O nó 10 passará a não ter mais um filho direito.

c) O nó 10 será promovido para a posição do nó 25.

d) A operação é inválida, pois o nó 15 não é uma folha.

e) A operação é inválida, pois o nó 15 não pode ser removido antes do nó 10.

13. Se o nó 10 fosse removido da Árvore Principal, qual afirmação descreveria a mudança na estrutura?

a) O nó 25 adotará o nó 15 como seu filho esquerdo.

b) O nó 30 adotará o nó 15 como seu filho esquerdo

c) O nó 15 também será removido em cascata.

d) O nó 25 também será removido em cascata.

e) A operação é inválida, pois o nó 10 não é uma folha.

14. Se o nó 50 fosse removido da Árvore Principal, qual afirmação descreveria a mudança na estrutura?

a) O nó 75 se tornará a nova raiz da árvore.

b) O nó 25 se tornará a nova raiz da árvore.

c) O nó 60 se tornará a nova raiz da árvore e o nó 75 se tornará o pai do nó 65.

d) O nó 60 se tornará a nova raiz da árvore e o nó 65 se tornará o pai do nó 75.

e) O nó 25 e o nó 75 se tornarão as raízes de duas novas árvores.

SEÇÃO D: AUTOAVALIAÇÃO E FEEDBACK

15. Em uma escala de 1 a 5, quão difícil você achou este questionário?

1 ( ) Muito fácil

2 ( ) Fácil

3 ( ) Médio

4 ( ) Difícil

5 ( ) Muito difícil

16. Qual questão você considerou a mais desafiadora e por quê?

GABARITO

Questão 1: Raiz da Árvore
Alternativa Correta: c) 50
Justificativa: A raiz é o único nó da árvore que não possui um nó pai. É o nó do topo da hierarquia, a partir do qual todos os outros nós descendem. Na árvore apresentada, este nó é o 50.

Questão 2: Nós Folha
Alternativa Correta: a) 15, 30, 45, 65, 85, 99
Justificativa: Nós folha são aqueles que não possuem filhos. Percorrendo a árvore, os nós que satisfazem essa condição são exatamente os listados na alternativa (a).

Questão 3: Nó Pai de 40
Alternativa Correta: d) 35
Justificativa: O nó pai é o nó que está diretamente acima de um nó na hierarquia. Seguindo a aresta que chega ao nó 40, identificamos que ele é o filho direito do nó 35.

Questão 4: Filhos de 75
Alternativa Correta: b) 60 e 90
Justificativa: Os filhos são os nós diretamente conectados e abaixo de um nó pai. O nó 75 possui uma subárvore esquerda iniciada pelo nó 60 e uma subárvore direita iniciada pelo nó 90.

Questão 5: Percurso em Pré-Ordem
Alternativa Correta: a) 50, 25, 10, 15, 35, 30, 40, 45, 75, 60, 65, 90, 85, 99
Justificativa: O percurso em pré-ordem segue a regra **Raiz -> Esquerda -> Direita**. O algoritmo visita o nó atual, depois percorre recursivamente toda a subárvore esquerda e, por fim, percorre recursivamente toda a subárvore direita.

Questão 6: Percurso em Em-Ordem
Alternativa Correta: c) 10, 15, 25, 30, 35, 40, 45, 50, 60, 65, 75, 85, 90, 99
Justificativa: O percurso em em-ordem segue a regra **Esquerda -> Raiz -> Direita**. Para uma Árvore Binária de Busca, este percurso tem a propriedade especial de visitar os nós em ordem crescente de seus valores.

Questão 7: Percurso em Pós-Ordem
Alternativa Correta: b) 15, 10, 30, 45, 40, 35, 25, 65, 60, 85, 99, 90, 75, 50
Justificativa: O percurso em pós-ordem segue a regra **Esquerda -> Direita -> Raiz**. O algoritmo percorre recursivamente toda a subárvore esquerda, depois toda a subárvore direita e, por último, visita o nó atual.

Questão 8: Inserção em BST
Alternativa Correta: b) O nó 42 se tornaria o filho esquerdo do nó 45, e o nó 88 se tornaria o filho direito do nó 85.

Justificativa: Para inserir 42, o caminho percorrido é 50->25->35->40->45. Como 42 < 45, ele é inserido à esquerda. Para inserir 88, o caminho é 50->75->90->85. Como 88 > 85, ele é inserido à direita.

Questão 9: Busca em BST
Alternativa Correta: c) 50, 25, 35, 40, 45
Justificativa: A busca em uma BST compara o valor alvo com o nó atual e decide se continua para a esquerda (se for menor) ou para a direita (se for maior), até encontrar o nó. O caminho 50 -> 25 -> 35 -> 40 -> 45 segue exatamente essa regra.

Questão 10: Nó Sucessor
Alternativa Correta: e) 60
Justificativa: O sucessor em-ordem de um nó (neste caso, 50) é o menor valor em sua subárvore direita. A subárvore direita de 50 é iniciada pelo 75. Para encontrar o menor valor nela, descemos pela esquerda o máximo possível: 75 -> 60. Como 60 não tem filho esquerdo, ele é o menor valor e, portanto, o sucessor.

Questão 11: Nó Antecessor
Alternativa Correta: d) 45
Justificativa: O antecessor em-ordem de um nó (50) é o maior valor em sua subárvore esquerda. A subárvore esquerda de 50 é iniciada pelo 25. Para encontrar o maior valor nela, descemos pela direita o máximo possível: 25 -> 35 -> 40 -> 45. Como 45 não tem filho direito, ele é o maior valor e, portanto, o antecessor.

Questão 12: Remoção de Nó Folha
Alternativa Correta: b) O nó 10 passará a não ter mais um filho direito.
Justificativa: A remoção de um nó folha (15) é a operação mais simples. Apenas a referência (ponteiro) de seu nó pai (10) que apontava para ele é alterada para null, efetivamente desconectando a folha da árvore.

Questão 13: Remoção de Nó com Um Filho
Alternativa Correta: a) O nó 25 adotará o nó 15 como seu filho esquerdo.
Justificativa: Ao remover um nó com um único filho (10), o nó pai do nó removido (25) "adota" o único neto (15). O ponteiro do pai (25), que apontava para o nó a ser removido (10), passa a apontar diretamente para o filho desse nó (15).

Questão 14: Remoção de Nó com Dois Filhos
Alternativa Correta: c) O nó 60 se tornará a nova raiz da árvore e o nó 75 se **tornará** o pai do nó 65.
Justificativa: Para remover um nó com dois filhos (50), usamos a regra do sucessor: encontrar o sucessor do nó 50, que é o nó 60; copiar o valor do sucessor (60) para o nó que seria removido; remover o nó original que continha o sucessor (60); aplicar a regra de remoção de nó com um filho: o pai do nó 60 (70) adota seu neto (65). Portanto, o nó 70 se torna o pai do nó 65, que passa a ser seu filho esquerdo.

8.3. Questionário de Satisfação do Uso da Ferramenta

QUESTIONÁRIO DE SATISTAÇÃO DO USO DA FERRAMENTA

Agradecemos imensamente sua participação na etapa prática desta pesquisa. Agora, nesta fase final, nosso objetivo é compreender a sua percepção sincera sobre a ferramenta *VisuAlgo*. Este breve questionário busca avaliar sua experiência de uso, o quão intuitiva e útil a ferramenta se mostrou para o seu aprendizado e o seu nível geral de satisfação. Por favor, pode ficar tranquilo e responder com sinceridade, pois não há respostas certas ou erradas; sua opinião honesta é a informação mais valiosa que podemos coletar. Suas respostas são totalmente anônimas, confidenciais e serão fundamentais para analisarmos o potencial de ferramentas interativas para aprimorar o ensino de Estrutura de Dados para futuras turmas.

INFORMAÇÕES GERAIS

Idade:

Período que está cursando:

Gênero: ( ) feminino ( ) masculino ( ) outros

Possui familiaridade com outras ferramentas similares: ( ) Sim ( ) Não

ESCALA DE USABILIDADE DA FERRAMENTA

1. Acho que usaria este sistema com frequência.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
2. Achei o sistema desnecessariamente complexo.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
3. Achei o sistema fácil de usar.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
4. Acho que precisaria de ajuda de uma pessoa com conhecimentos técnicos para usar o sistema.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
5. Achei que as várias funções do sistema estavam muito bem integradas.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
6. Achei que o sistema tinha muita inconsistência.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
7. Imagino que a maioria das pessoas aprenderia a usar este sistema muito rapidamente.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo
8. Achei o sistema muito complicado de usar.
   ( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo

9. Senti-me muito confiante ao usar o sistema.

( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo

10. Precisei aprender muitas coisas novas antes de conseguir usar o sistema.

( ) Concordo ( ) Concordo parcialmente ( ) Neutro ( ) Discordo parcialmente ( ) Discordo

ESCALA DE SATISFAÇÃO DA FERRAMENTA

11. Em uma escala de 0 a 10, o quão provável é que você recomende a ferramenta *VisuAlgo* para um amigo ou colega de curso?

0 ( ) **Nada Provável**

1 ( ) ...

2 ( ) ...

3 ( ) ...

4 ( ) ...

5 ( ) ...

6 ( ) ...

7 ( ) ...

8 ( ) ...

9 ( ) ...

10 ( ) **Extremamente Provável**